

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ
ВЫСШЕГО ОБРАЗОВАНИЯ
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет социальных наук

Камалов Артур Наилевич

**АВТОМАТИЧЕСКАЯ КОДИРОВКА ОТКРЫТЫХ ОТВЕТОВ В
СОЦИОЛОГИЧЕСКИХ ОПРОСАХ: СРАВНЕНИЕ МОДЕЛЕЙ
МАШИННОГО ОБУЧЕНИЯ**

Выпускная квалификационная работа - БАКАЛАВРСКАЯ РАБОТА
по направлению подготовки 39.03.01 Социология
образовательная программа «Социология»

Рецензент
к. социол. н., доцент
А. Н. Ротмистров

Руководитель
к. социол. н., доцент
И. К. Зангиева

Москва 2026

Оглавление

Введение	4
1 Теоретические основы исследования	10
1.1 Типы вопросов по наличию вариантов ответов	10
1.2 Сравнение открытых и закрытых вопросов	11
1.3 Типы открытых вопросов	13
1.4 Типология кодировочных задач	14
1.5 Ручное кодирование	15
1.6 Кодирование как классификация	16
1.7 Автоматическое кодирование	17
1.8 Представление текстовых данных для моделей	18
1.9 Модели классического машинного обучения	21
1.9.1 Логистическая регрессия	22
1.9.2 Наивный байесовский классификатор	24
1.9.3 Метод опорных векторов	25
1.9.4 Случайный лес	26
1.9.5 Градиентный бустинг	27
1.10 Модели глубинного обучения	29
1.10.1 Сверточные нейронные сети	30
1.10.2 Рекуррентные нейронные сети	32
1.10.3 Трансформеры	34
1.11 Метрики оценки качества классификации	36
1.12 Эмпирические исследования сравнения моделей	38
1.13 Резюме теоретической главы	40
2 Методология сравнительного анализа	41
2.1 Основные понятия	41
2.2 Эмпирическая база	41

2.3	Экспериментальный дизайн	46
3	Эмпирические результаты	55
3.1	Обучение моделей	55
3.2	Оценка полученного качества классификации	57
	Заключение	62
	Список литературы	64
	Приложения	75
1	Кодировочная система ANES 2008	75
2	Репозиторий исследования	82

Введение

Актуальность и проблемная ситуация

Открытые вопросы используются в социологических опросах как инструмент получения более точной, развернутой и содержательно насыщенной информации [Geer, 1991, с. 367; Roberts et al., 2014, с. 1065], поскольку, в отличие от закрытых вопросов, они позволяют избежать жесткого навязывания категорий и дают возможность получить смыслы из индивидуальных формулировок респондентов [Neuert et al., 2021, с. 3].

Тем не менее, включение открытых вопросов в инструментарий исследования неизбежно связано с необходимостью последующей кодировки этих ответов по кодировочной системе (кодбуку) [Woike, 2007, с. 300; Ryan, Bernard, 2003, с. 85], то есть их перевода в аналитически пригодный вид для дальнейшего анализа [Paleardi, Novello, 2025, с. 4]. В рамках классического подхода кодировка открытых ответов осуществляется вручную и предполагает разработку кодбука с представленными категориями, обучение кодировщиков и контроль их ответов [Haaland et al., 2024, с. 16; Züll, 2016, с. 4]. Масштабирование данной процедуры определённо является задачей трудоемкой, затратной по времени и ресурсам [Converse, 1984, с. 272], а также подверженной вариативности интерпретаций кодировщиков [O'Connor, Joffe, 2020, с. 2; Armstrong et al., 1997, с. 605; Esuli, Sebastiani, 2010, с. 3].

Кодирование открытых ответов можно рассмотреть как задачу классификации [Sebastiani, 2002, с. 3; Giorgetti, Sebastiani, 2003, с. 1272; Aggarwal, Zhai, 2012, с. 164], предполагающую сопоставление каждого объекта из множества X одной из категорий из конечного множества Y .

$$f: X \rightarrow Y, \tag{1}$$

где Y — дискретное множество меток.

Задача классификации текстовых ответов может решаться с помощью машинного обучения [Schonlau, Gweon, Wenemark, 2021, с. 563; Joachims, 1998, с. 2; Canché, 2023, с. 3]. Машинное обучение можно разделить на классическое машинное обучение и глубинное обучение. Для решения задачи классификации наиболее часто применяются такие модели классического машинного обучения, как логистическая регрессия, метод опорных векторов (SVM), деревья решений и их ансамбли (случайный лес, градиентный бустинг), наивный байесов-

ский классификатор и др. [Palanivinyagam, El-Bayeh, Damaševičius, 2023, с. 6]. Глубинное обучение для задачи классификации представлено, в основном, следующими архитектурами: свёрточные сети (CNN), рекуррентные сети (RNN) [Luan, Lin, 2019, с. 352], а в последнее время большое распространение получили трансформеры [Minaee et al., 2021, с. 3], благодаря основанным на них большим языковым моделям (LLM). Архитектура трансформеров делится на encoder-модели (например, BERT) и decoder-модели (например, ChatGPT). Основным решением для классификации текста являются encoder-модели, часто показывающие выдающиеся результаты в задаче текстовой классификации, в то время как decoder-модели применяются реже [Gasparetto et al., 2022, с. 19]. Однако у decoder-моделей также есть потенциал в задаче классификации, поскольку они могут быстро обучиться решать поставленную задачу классификации на основе системных инструкций (промптов) и использования обучающих примеров [Izacard et al., 2023, с. 1], в том числе с помощью применения retrieval few-shot подхода [Rubin, Herzig, Berant, 2022, с. 1], при котором в промпт добавляется небольшое число наиболее похожих размеченных примеров из обучающей выборки для предсказания на тестовой выборке.

На фоне всеобщей автоматизации с развитием технологий по обработке текстовых данных и роста объемов этих данных, все большую популярность получают методы обработки текста на основе машинного обучения [Стукал, Беленков, Филиппов, 2021, с. 48; DiGiuseppe, Flynn, 2026, с. 2]. Начиная с 2000-х годов машинное обучение всё чаще рассматриваются как потенциальная альтернатива или дополнение к ручной кодировке открытых ответов [Giorgetti, Sebastiani, 2003, с. 1276], при этом модели всё сильнее развиваются. В последние годы модели глубинного обучения, а именно, большие языковые модели (LLM) на основе архитектуры трансформеров (например, BERT) в различных задачах обработки текста потенциально позволяют достигать значительно лучшего качества [Gardazi et al., 2025, с. 7] по сравнению с моделями классического машинного обучения (например, логистическая регрессия) [Ramzan et al., 2024, с. 4]. LLM произвели революцию в том числе во многих задачах классификации текстов [Fields, Chovanec, Madiraju, 2024, с. 6518], но в то же время, в эмпирических исследованиях по кодированию именно открытых ответов модели классического машинного обучения (например, логистическая регрессия) часто показывают сопоставимое с LLM качество классификации, а в отдельных случаях даже превосходят их, особенно при небольшом объёме обучающей выборки и кодировании хорошо интерпретируемых категорий [Meidinger, Aßenmacher, 2021, с. 871]. Предполагается, что качество автоматической кодировки существенно варьируется в зависимости от типа открытого вопроса. Нет четкого понимания того, какое качество кодирования показывают различные модели машинного обучения применительно к разным типам вопросов и в каких случаях автоматическая кодировка может рассматриваться как допустимая операция.

Проблема исследования

Остается неясным, в какой степени различия в качестве кодирования (классификации) между моделями обусловлены типом открытого вопроса, задающим разную степень семантической сложности и вариативности ответов, соответственно, отсутствие систематического сравнения моделей с учетом типологии открытых вопросов формирует пробел в понимании условий их эффективного применения. Более того, несмотря на декларируемое в литературе преимущество моделей глубинного обучения во множестве задач обработки текста [Young et al., 2018, с. 55; Otter, Medina, Kalita, 2020, с. 1], в исследованиях автоматического кодирования открытых ответов они нередко демонстрируют качество, сопоставимое с моделями классического машинного обучения [Meidinger, Aßenmacher, 2021, с. 871], в связи с чем есть рассогласованность между ожидаемыми теоретическими и эмпирическими результатами.

Основной исследовательский вопрос

Как различается качество автоматической кодировки открытых ответов с помощью разных моделей классического машинного обучения и глубинного обучения в зависимости от типа открытого вопроса?

Теоретический объект

Автоматическое кодирование ответов на открытые вопросы разного типа как исследовательская процедура в социальных исследованиях.

Предмет исследования

Качество автоматической кодировки открытых ответов моделями классического машинного обучения и глубинного обучения в зависимости от типа открытого вопроса.

Эмпирический объект исследования и база

Объектом исследования являются открытые ответы и присвоенные им категории кодирования. Используются результаты ANES 2008 Open Ended Coding Project. В 2008 году в выборку вошло 2102 жителя США, имеющих право голоса. Данные собраны посредством личного анкетирования. Вся выборка состоит из 10 датасетов. В каждом датасете содержатся ответы на один или несколько открытых вопросов. Вопросы объединялись не произвольным образом: каждый датасет представляет собой блок вопросов, для которых в ANES 2008

Open Ended Coding Project использовалась общая кодировочная рамка. Иначе говоря, внутри одного датасета объединяются вопросы, вручную кодируемые через единое пространство содержательных категорий.

Цель исследования

Сравнить возможности и ограничения моделей классического машинного обучения и глубинного обучения при автоматической кодировке ответов на открытые вопросы различного типа в социальных опросах.

Задачи исследования

1. Рассмотреть существующие подходы к автоматическому кодированию открытых ответов на основе моделей классического машинного обучения и глубинного обучения.
2. Проанализировать способы оценки качества кодирования открытых ответов (классификации).
3. Обосновать выбор релевантного критерия оценки качества классификации в задаче кодирования открытых ответов.
4. Сравнить качество кодирования (классификации) открытых ответов при использовании моделей классического машинного обучения и глубинного обучения.
5. Сформулировать методические рекомендации для практического кодирования разных типов открытых ответов на основе результатов сравнительного анализа качества классификации моделей.

Гипотезы исследования

Гипотезы относятся к эмпирической задаче №4

1. В задаче кодирования (классификации) действительно открытых вопросов модели глубинного обучения демонстрируют более высокое качество классификации по сравнению с моделями классического машинного обучения.

Обоснование: действительно открытые вопросы отличаются большой семантической вариативностью и неоднозначностью, а некоторые модели глубинного обучения лучше учитывают контекст и семантические отношения в тексте по сравнению с классическими моделями [[Gardazi et al., 2025, с. 2](#)].

2. В задаче кодирования (классификации) действительно открытых вопросов decoder-based LLM (GigaChat), использующая контекстную информацию через few-shot промптинг, демонстрирует более высокое качество классификации по сравнению с encoder-based LLM (DistilBERT).

Обоснование: современные генеративные модели с decoder-архитектурой могут быть значительно эффективнее для классификации текста, чем модели encoder-архитектуры, требующие дообучения под конкретную задачу классификации. [Mellon et al., 2024, с. 6]

3. В задаче кодирования (классификации) кажущихся открытыми вопросов различия в качестве классификации между моделями классического машинного обучения и глубинного обучения статистически незначимы.

Обоснование: ожидаемое преимущество глубинного обучения должно проявляться прежде всего там, где требуется моделировать сложную семантику ответа, тогда как в более стандартизированных задачах классификации ответов на кажущиеся открытыми вопросы может быть достаточно простых моделей машинного обучения [Paleardi, Novello, 2025, с. 18], особенно при хорошем подборе признаков [Joulin et al., 2017, с. 427]. В целом, в некоторых задачах кодирования открытых текстовых ответов выбор более сложного алгоритма не всегда радикально меняет качество классификации [Schierholz, Schonlau, 2021, с. 1030-1031].

Научная новизна

Предполагается установить, при каких типах открытых вопросов (кажущиеся открытыми, действительно открытые) наблюдаются различия в эффективности применения моделей классического машинного обучения и глубинного обучения. Научная новизна данного исследования заключается в комплексном сравнительном анализе различных поколений моделей в задаче кодирования ответов, принимая в особое внимание применение моделей к разным типам открытых вопросов. К тому же, в отличие от большинства существующих исследований, сосредоточенных либо на классических алгоритмах машинного обучения, либо на отдельных нейросетевых архитектурах, в данной работе проводится систематическое сопоставление нескольких наиболее популярных моделей классического машинного обучения и глубинного обучения. В некоторой степени новизной является использование режима retrieval-augmented промптинга, позволяющего LLM получить примеры кодировки при классификации похожих текстовых ответов, который ранее не рассматривался в контексте задачи кодирования открытых ответов. Научная и практическая значимость работы состоит в прояснении условий применимости различных моделей для автоматической кодировки, что позволяет обосновать выбор моделей в зависимости от типа открытого вопроса и, тем самым, уточнить границы использования автоматической кодировки как альтернативы ручной.

Ограничения исследования

Во-первых, задача кодирования открытых ответов понимается только как классификация, то есть предполагается наличие обучающей выборки с выполненной разметкой кодов. Во-вторых, анализ проводится на основе одного корпуса открытых ответов, сформированного в рамках исследования ANES 2008, что ограничивает обобщаемость результатов на другие опросы, тем не менее, база включает открытые вопросы различных типов, что делает её репрезентативной с точки зрения типологии открытых вопросов и позволяет проводить обоснованное сравнение моделей. В-третьих, результаты сравнения моделей зависят от точной настройки моделей и выбора гиперпараметров в процессе обучения, которые также зависят от особенностей конкретного датасета, включая распределение категорий и объём обучающей выборки.

Структура работы

Текст работы состоит из введения, трёх содержательных глав, заключения и приложений. В первой главе описаны теоретические основы исследования: приводятся особенности открытых вопросов и их кодирования, а также рассматриваются модели машинного обучения, с помощью которых это кодирование можно осуществить. Задача кодирования открытых ответов ставится как задача классификации. Во второй главе представлена методология исследования, а именно описан дизайн эксперимента, критерии сравнения качества классификации моделей. В третьей главе представлены эмпирические результаты и их обсуждение, после чего в заключении подводятся итог проверки поставленных исследовательских гипотез и даётся методическая рекомендация по выбору модели в зависимости от типа открытого вопроса. В приложениях представлены подробные таблицы кодировочной системы ANES 2008.

Декларация использования ИИ

В данной работе декларируется использование ИИ — большой языковой модели GigaChat, которая применялась исключительно как одна из сравниваемых моделей глубинного обучения для автоматического кодирования: с её помощью были получены предсказания кодов для открытых ответов в рамках экспериментального сравнения качества классификации. Использованные промпты представлены в таблице 3.1 в части описания эмпирических результатов сравнения моделей. GigaChat не использовался для генерации текста работы.

Глава 1

Теоретические основы исследования

План обзора литературы

Вначале будут рассмотрены различия между открытыми и закрытыми вопросами в социальных исследованиях, а также выделены типы открытых вопросов и связанные с ними задачи кодирования. Далее кодирование открытых ответов будет рассмотрено как измерительная процедура, после чего обсуждается роль машинного обучения. Анализируются основные способы представления текстовых данных и приводится обзор моделей, используемых для классификации текстов. Далее рассмотрены метрики качества для задачи классификации. В заключительной части рассмотрены результаты эмпирических исследований, посвящённых автоматическому кодированию открытых ответов.

1.1. Типы вопросов по наличию вариантов ответов

В количественной социологии для исследователя важна конкретизация изучаемого объекта, поэтому важным фактором является понимание того, что он измеряет и каким образом это делает [Толстова, 2000, с. 54], в том числе с помощью вопроса в анкете. Традиционно в литературе, касающейся опросных методов социальных исследований, принято делить вопросы на открытые и закрытые [Pate, 2012, с. 31]. Открытым считается такой вопрос, в ответ на который респонденту предлагается сформулировать свой ответ, используя свои собственные слова [Bradburn, Sudman, Wansink, 2004, с. 153]. Отметим, что в эмпирических исследованиях открытые вопросы можно трактовать с двух сторон: в широком смысле к ним относятся ситуации во время нестандартизированного интервью, в котором интервьюер не ограничивается жёстко заданной формулировкой, а использует открытые реплики и иные коммуникативные средства для поддержания и развития ответа респондента, в узком же смысле открытый вопрос рассматривается как разновидность анкетного вопроса, отличающаяся отсутствием заранее предложенных категорий ответа [Саганенко, 2001, с. 173]. Таким образом, в противопоставление открытым вопросам закрытыми являются вопросы, вместе с которыми

ми респонденту предоставляется список из возможных вариантов ответа [Groves et al., 2011, с. 223], именно такой тип вопросов используется чаще всего в социальных исследованиях при составлении анкеты [Tourangeau, Rips, Rasinski, 2000, с. 231]. Различие между открытым и закрытым вопросом можно показать на простом примере вопроса о числе обращений к врачу за последние 12 месяцев в таблице 1.1 ниже [Couper et al., 2011, с. 2]. Содержательно оба вопроса направлены на измерение одной и той же характеристики, однако формат ответа задаёт разные условия получения данных.

Таблица 1.1: Пример открытого и закрытого формата одного и того же вопроса

Тип вопроса	Формулировка	Формат ответа
Открытый	В течение последних 12 месяцев сколько раз Вы посещали врача или разговаривали с ним о состоянии Вашего здоровья?	_____ раз
Закрытый	В течение последних 12 месяцев сколько раз Вы посещали врача или разговаривали с ним о состоянии Вашего здоровья?	☐ Ни разу ☐ 1 раз ☐ 2 раза ☐ 3 раза и более

Как можно заметить, деление вопросов на типы связано именно с форматом предъявления ответа, а не с темой вопроса. Отличием между формой собранных ответов является степень предварительной стандартизации ответа, которую исследователь желает получить для последующего анализа [Schuman, 1966, с. 218].

Несмотря на то, что данная работа посвящена именно открытым вопросам в анкетах, далее важно рассмотреть, какими методологическими преимуществами и ограничениями обладает каждый тип вопроса, в особенности, открытый.

1.2. Сравнение открытых и закрытых вопросов

Согласно устоявшейся методологии проведения социальных исследований, открытые вопросы отлично показывают себя при недостаточной степени разработки темы исследования, а также её сложности, когда ещё не были найдены релевантные критерии измерения [Stacey, 2013, с. 80]. То есть открытые вопросы используются при проведении разведочного этапа исследования, так как они полезны для определения смыслов, которые воспроизводят респонденты и конструирования качественных закрытых альтернатив для дальнейшего создания целевого формата анкеты [Schuman, Presser, 1979, с. 693]. Выбор открытых вопросов обуславливается их преимуществом перед закрытыми в случаях, когда нужно избежать давления и подталкивания респондента к определённому заданному ответу, поскольку при использовании открытого вопроса можно получить свободно выраженную мысль [Саганенко, 2001, с. 174; Neuert et al., 2021, с. 3]. Кроме того, исследователь может получить варианты ответов, которые ускользали от него в процессе первичного исследования темы и литера-

туры, получая ответ из реального сознания человека [Ядов, 2000, с. 256]. Как было сказано ранее, открытые вопросы могут служить для пилотажа или первичного сбора данных, и, зачастую, на практике опросов с большими выборками происходит именно так [Рогозин, 2001, с. 31]. В свою очередь, разработанные по такому принципу закрытые вопросы оказываются аналитически сильнее, так как они позволяют определять вербально разные, но концептуально одинаковые формы ответов без риска столкнуться с нечеткостью выражения мысли респондентом с одной стороны, и недопонимания со стороны кодировщика с другой [Schuman, Presser, 1979, с. 704]. Тем не менее, закрытые вопросы навязывают рамку ответа для респондента, тогда как открытые позволяют выразить мысль самостоятельно [Schuman, Presser, 1979, с. 693]. Априори нельзя сказать о преимуществе того или иного типа вопроса без понимания исследовательской цели. Резюмируя наиболее частый сценарий опросного исследования, закрытые вопросы применяются на этапе финального измерения по большой выборке, в то время как открытые нужны на этапе разведки, отсылая к традиции, сформированной Лазарсфельдом [Reja et al., 2003, с. 161-162]. Открытые вопросы рискованнее, так как они увеличивают вероятность пропусков в ответах, некачественных формулировок [Reja et al., 2003, с. 174-175].

Сведём особенности открытых и закрытых вопросов в таблице 1.2 ниже для обобщения различий между ними [Рогозин, 2001, с. 30].

Таблица 1.2: Свойства открытых и закрытых вопросов в соответствии с Рогозиным Д. М.

Открытые вопросы	Закрытые вопросы
(а) позволяют респондентам выразить мысли своими словами	(а) предполагают ответы в заданном формате, которые легко объединяются и анализируются
(б) не предлагают готовых ответов, что позволяет определить: степень знакомства респондентов с обсуждаемой темой, наиболее важные для них темы, степень переживаний	(б) приводят к незначительным разбросам ответов
(в) не подвержены эффектам формулировки вопроса, в том числе порядку расположения подсказок	(в) не требуют дополнительных усилий для формулирования ответа и вспоминания нужной информации, поэтому проще воспринимаются респондентами
(г) выявляют причины ответа и общие рамки представлений индивида	(г) могут вызвать затруднения у респондента, особенно если вопрос составлен в непривычной для него форме
(д) позволяют тестировать как варианты ответов на закрытые вопросы, так и неразработанные гипотезы	(д) теряются спонтанные и не вписывающиеся в рамки вопроса ответы
(е) помогают интерпретировать нестандартные ответы на закрытые вопросы	(е) возникают смещения при выборе заданных вариантов ответа
(ж) требуют больших материальных и временных ресурсов на кодирование и интерпретацию	

Мы рассмотрели то, что открытый вопрос, сохраняющий высказывание в его первоначальной языковой форме имеет ряд преимуществ. В контексте настоящего исследования важно помнить об этих преимуществах, поскольку это делает актуальным использование открытых ответов, и, соответственно, задачу нахождения надёжных способов их автоматизированного кодирования. Теперь подробнее рассмотрим, какие типы открытых вопросов есть.

1.3. Типы открытых вопросов

По принципиальным различиям можно выделить три категории открытых вопросов, основываясь на классификации ниже [Popping, 2015, с. 25].

1. *Технически открытый вопрос.* Данный тип является функциональным аналогом закрытого вопроса, поскольку требует строго определённого ответа и, как правило, используется для ввода числовых значений, например года рождения. Иными словами, исследователь не перечисляет все возможные варианты ответа, а оставляет респонденту необходимость самостоятельного ввода нужного значения. Такой вопрос используется прежде всего для удобства респондента и сокращения объёма анкеты.

Пример: «В каком году Вы родились?»

2. *Кажущийся открытым вопрос.* Данный тип предполагает формальный ввод текстового ответа, однако исследователь заранее знает все допустимые варианты ответа. Обычно такой формат используется во избежание предъявления респонденту слишком длинного списка вариантов. Подобные вопросы применяются в тех случаях, когда ответы в принципе можно свести к заранее существующему перечню, например при указании религиозной принадлежности, этнической принадлежности, языка, на котором говорят дома, или читаемых журналов.

Пример: «Какие газеты Вы читаете дома?»

3. *Действительно открытый вопрос.* Данный тип не предполагает заранее заданного и исчерпывающего множества категорий ответа, известных исследователю. С аналитической точки зрения именно этот тип вопросов позволяет выявлять новые смыслы, которые продуцируют респонденты.

Пример: «Почему Вы проголосовали за эту политическую партию?»

Исследователь на этапе дизайна своего исследования и анкеты должен знать, как он будет анализировать действительно открытые вопросы, поскольку предполагается, что из соответствующих ответов будут сделаны содержательные смысловые выводы [Popping, 2015, с. 26]. Плохо сформулированный открытый вопрос не даёт анализируемых данных и не должен включаться в анкету. Как можно заметить, *технически открытый вопрос* требует лишь

базовой предобработки полученных данных, поэтому он неактуален для моего исследования, направленного на сравнение моделей машинного обучения в задаче кодирования, так как применение сложных моделей будет нецелесообразно и нерационально. Кодирования требуют только два типа вопросов, а именно: *кажущийся открытым вопрос* и *действительно открытый вопрос*. Принципиальная проблема двух упомянутых типов открытых вопросов заключается в сложности кодирования [Leiva, Ríos, Martínez, 2006, с. 520; Esuli, Sebastiani, 2010, с. 1] и требовании дополнительных усилий для него [Scholz, Dorer, Zuell, 2022, с. 80], из чего следует нагрузка на исследователей, анализирующих данные [Haensch et al., 2022, с. 2] и, следовательно, временная и материальная дороговизна обработки ответов на открытые вопросы. Этап кодирования ответов важен не меньше правильной формулировки вопросов и является переводом смысла, заложенного респондентом в аналитическую форму с учётом контекста высказывания [Климова, 2006, с. 17]. Кодирование больших датасетов зачастую осуществляется не одним, а несколькими кодировщиками, но при усложнении задачи кодирования ответов возрастает рассогласованность кодировщиков, соответственно растёт ошибка измерения [Popping, 2015, с. 32; Glazier, Boydston, Feezell, 2021, с. 3]. То есть ручное кодирование открытых ответов сталкивается с проблемой субъективных интерпретаций человека-кодировщика [Armstrong et al., 1997, с. 605], что снижает воспроизводимость результатов при отнесении одного и того же ответа к определённой категории, поэтому возникает необходимость в таких процедурах кодирования, которые опирались бы на более формализованные и единообразные правила обработки текстовых данных, чтобы процедура кодирования в меньшей степени была субъективной.

Мы рассмотрели типы открытых вопросов и проблематизировали задачу их кодирования, обусловленную временными и материальными затратами, а также рассогласованностью мнений кодировщиков между собой. Ниже подробнее рассмотрим кодировочные задачи для соотнесения их с типами открытых вопросов.

1.4. Типология кодировочных задач

Кодировочные задачи можно классифицировать по нескольким типам, которые также соотносятся с приведённой ранее типологией открытых вопросов [Montgomery, Crittenden, 1977, с. 236-237].

1. *Тип А.* Данный тип обладает минимальной сложностью в задаче кодирования, так как не предполагается интерпретации со стороны исследователя, поскольку есть один правильный однозначный ответ, который респондент уже дал в фиксированном месте. Аналитически такой вопрос можно считать закрытым, поэтому методологически он обладает наиболее высокой надёжностью и минимальной ошибкой измерения.
2. *Тип В.* Данный тип предполагает поиск релевантного для исследователя смысла в ответе респондента, но релевантность неочевидна, то есть требуется интерпретация в

рамках контекста ответа. Здесь увеличивается вероятность неправильного кодирования.

3. *Тип В1*. Данный тип характеризуется выделением нескольких содержательных смыслов из ответа респондента, которые требуют дополнительного ранжирования их между собой и редукции их к одному наиболее значимому аналитическому коду. В данной задаче кодировки крайне затруднительна автоматизация без потери качества [Popping, 2015, с. 34].

Как видим, можно соотнести задачу кодирования типа В с *кажущимся открытым вопросом*, а задачу типа В1 с *действительно открытым вопросом*.

Мы типизировали задачи кодирования и соотнесли их с типами вопросов, кодирование которых хотим автоматизировать. Но перед этим важно рассмотреть особенности ручного кодирования.

1.5. Ручное кодирование

В ручном кодировании можно выделить две стратегии: кодирование эксплицитных значений и кодирование смыслов, приписываемых исследователем [Оберемко, 2018, с. 103]. Первая ориентирована на фиксацию непосредственно выраженных значений, то есть на объединение в один код тех ответов, которые по-разному сформулированы, но указывают на один и тот же объект, признак или позицию. Вторая стратегия связана с выделением интерпретативных смыслов, которые не даны в ответе напрямую, а конструируются исследователем в ходе аналитического обобщения. Если в первом случае кодирование направлено на упорядочивание явно выраженного содержания ответов, то во втором на отнесение этих ответов к более абстрактным аналитическим категориям. Для разработки воспроизводимой процедуры кодирования принципиально важно, чтобы на начальных этапах классификация строилась прежде всего на эксплицитно представленных значениях, тогда как переход к интерпретации смыслов должен осуществляться позднее и быть специально обоснован. В целом, ручное кодирование является процессом, в котором кодировщик выделяет текстовые единицы в ответе респондента, затем соотносит их с концептуальными категориями, которые определены заранее по заданным правилам с помощью кодбука [Glazier, Boydston, Feezell, 2021, с. 1]. Разработка кодбука может осуществляться по трём основным стратегиям [Popping, 2015, с. 33]. Первая предполагает априорное конструирование категорий на основании теории, лежащей в основе исследования. Вторая опирается на индуктивную логику и предполагает апостериорное выделение категорий, исходя из языкового материала анализируемых ответов. Третья стратегия сочетает оба подхода, то есть исходный набор кодов задаётся теоретически, но в дальнейшем модифицируется и расширяется с учётом эмпирических данных.

Мы зафиксировали, что представляет из себя ручное кодирование, которое определённо остаётся идеалом, если выполняется без ошибок и полностью удовлетворяет целям исследователя, разработавшего анкету, то есть скорее всего выполняется лично исследователем.

1.6. Кодирование как классификация

Кодирование по разработанному кодбуку является процедурой, при которой каждый неструктурированный открытый ответ респондента нужно отнести к определённой категории [Paleardi, Novello, 2025, с. 4]. При этом важно отметить, что «„кодирование“ — это процедура сжатия и систематизации текстового материала. Поэтому правильно говорить не „кодирование“, а „классификация“ — ведь мы не просто приписываем словам цифровые значения, а раскладываем их „по ящичкам“ логически упорядоченного классификатора» [Климова, 2006, с. 19].

В связи с ростом объёмов доступной информации для современного социолога [Толстова, 2015, с. 6] всё чаще рассматривается возможность автоматизации, в том числе процесса кодирования [Grimmer, Roberts, Stewart, 2021, с. 410]. Если кодирование открытых ответов можно понимать как задачу классификации, её можно автоматизировать, в частности, с помощью моделей машинного обучения. Методы машинного обучения подразделяются на три основных типа: методы обучения с учителем, без учителя и обучение с подкреплением [Pandey, Niwaria, Chourasia, 2019, с. 916]. В нашем исследовании нас интересуют в первую очередь модели машинного обучения с учителем, поскольку нам необходимо решать задачу классификации. Итак, для классификации открытых ответов можно применять машинное обучение с учителем, которое предполагает обучение модели на данных (в нашем случае открытых текстовых ответах) с известными метками (кодами из кодбука) для предсказания метки (кода) на новых данных с минимальной ошибкой [Nasteski, 2017, с. 2]. Отмечу ещё раз, что человек-кодировщик тоже выполняет классификацию, но только ручную, а модель машинного обучения лишь автоматизирует процесс посредством предсказания определённой метки из заданного подмножества категорий кодбука с помощью модели машинного обучения. В этом случае модель обучается на небольшой размеченной выборке данных, где ответы уже классифицированы человеком, и затем используется для предсказания соответствующих категорий в большом массиве неразмеченных ответов. В таком случае методы машинного обучения позволяют распространить результаты ручной разметки на значительно более крупные наборы данных, экономя человеческие ресурсы. Соответственно, измерение интересующих исследователя характеристик всего датасета становится возможным, когда ручное кодирование выполнено лишь для ограниченной части наблюдений, что снижает трудоемкость и дороговизну процесса. При этом автоматическое кодирование может формализовать процесс кодирования, позволив избежать ошибки, связанной с различными субъективными интерпретациями нескольких кодировщиков [Burrows, Gurevych, Stein, 2015, с. 61].

Здесь важно отметить, что само по себе автоматическое кодирование не стремится научиться кодировать «объективно корректно» [Esuli, Sebastiani, 2010, с. 3], поскольку кодирование — это априори субъективная задача и модель будет воспроизводить ту субъективность, с которой ответы кодировал человек. Преимущество автоматизации здесь в том, что не будет происходить разногласий как в ручном кодировании между несколькими кодировщиками.

Мы определили кодирование как задачу классификации, решение которой можно автоматизировать с помощью машинного обучения. Теперь рассмотрим подходы к автоматическому кодированию открытых ответов.

1.7. Автоматическое кодирование

Автоматическое кодирование может являться как классификацией текстов по существующим категориям, так и по категориям, которые еще предстоит создать [Grimmer, Stewart, 2013, с. 294]. Напомню, что в настоящем исследовании нас интересует именно классификация, а не кластеризация, поскольку последняя подходит больше для первичного, разведочного анализа, так как помогает обнаружить группы похожих ответов [Senderovich, May-suradze, 2015, с. 201], но для стабильного автоматического кодирования требуется воспроизвести именно заданную на обучающей выборке исследователем схему кодирования. Это соотносится с общей логикой исследований в области автоматического кодирования открытых ответов: в большинстве случаев задача формулируется как классификация, находясь в области машинного обучения с учителем [Horbach, Pinkal, 2018, с. 4065], благодаря чему можно количественно оценить качество модели через сравнение ее предсказаний с «эталонной» ручной разметкой. Итак, стоит отметить, что как таковые попытки автоматизации, призванные прежде всего ускорить процесс кодирования, применялись с конца 20 века, но были основаны на словарях, то есть определении вхождения заданных слов-кодов в ответ респондента [Giorgetti, Sebastiani, 2003, с. 1270]. Следующим подходом в начале 21 века является применение классического машинного обучения с учителем, для которого предполагается наличие сравнительно небольшой обучающей выборки вручную размеченных открытых ответов респондентов по нескольким категориям [Giorgetti, Sebastiani, 2003, с. 1272]. Это видится более эффективным способом кодирования по сравнению с использованием детально настроенного словаря кодов, хотя применение рассматриваемого ими метода целесообразно в случаях средних или больших объемов опросных данных, так как для малых выборок полная ручная разметка не является критически затратной.

Важно подчеркнуть, что для методов кодирования на основе машинного обучения критически важна концептуальная валидация качества кодирования в сопоставлении с кодированием силами человека [Grimmer, Stewart, 2013, с. 271], отсюда следует важность наличия качественной обучающей выборки и представительная выборка текстов [Arief, Deris, 2021, с. 1; Rajman, Vesely, 2004, с. 9], потому что плохую обучающую выборку нельзя исправить хорошим мощным алгоритмом.

Текстовая классификация обычно осуществляется в очень высокоразмерном, но разреженном пространстве текстовых признаков, где у текстового ответа есть много потенциально возможных слов, но при этом реально встречается лишь небольшая их часть [Joachims, 1998, с. 3]. Стоит заметить, что именно высокая размерность, разреженность и избыточность признаков может быть полезной для некоторых алгоритмов машинного обучения, в частности, SVM [Joachims, 2001, с. 136].

Стоит отметить идею того, что для кодирования открытых ответов возможен полуавтоматический подход, то есть часть текстов кодируется алгоритмом, а сложные случаи остаются для человека [Schonlau, Couper, 2016, с. 144; Andersen, Zehner, Goldhammer, 2023, с. 849]. Автоматизация не обязательно должна быть полной, поэтому при заданном пороге уверенности можно балансировать между долей автоматического кодирования и ожидаемой точностью кодирования. Отмечается, что при осуществлении полуавтоматического подхода при кодировании, когда модель не кодирует наиболее затруднительные ответы, важен порядок, в котором человек самостоятельно анализирует сложные ответы, желательно ранжирование ответов по вероятности ошибки, вследствие чего человек-кодировщик тратит меньше усилий для прироста качества кодирования [Berardi, Esuli, Sebastiani, 2014, с. 493]. В целом, любая автоматизация с помощью машинного обучения должна быть обоснована и валидна для конкретной задачи, поэтому не стоит использовать машинное обучение ради машинного обучения [Rudin, 2019, с. 206]. Строго говоря, автоматизация требуется именно при больших размерах выборок открытых ответов для оправдания сложности применяемых моделей [Zhang et al., 2023, с. 325].

Далее рассмотрим, как передать открытые ответы в модель классификации.

1.8. Представление текстовых данных для моделей

Чтобы обучить модель машинного обучения, текстовые данные необходимо предварительно подготовить. Поскольку алгоритмы не способны напрямую работать с текстом, информация из текстов должна быть преобразована в набор числовых признаков, пригодных для дальнейшего анализа [Захарова, Вишнякова, Детков, 2025, с. 300]. При этом на начальном этапе выполняется нормализация текста, направленная на снижение объёма нерелевантной и шумовой информации. Текст приводится к единому регистру, а также удаляются знаки препинания и различные символы, которые, как правило, не вносят существенного вклада в смысловое содержание [Andersen, Zehner, Goldhammer, 2023, с. 843]. Следующим этапом является токенизация, то есть разбиение текста на элементарные единицы, называемые токенами, при этом в зависимости от целей анализа в качестве токенов могут рассматриваться как отдельные слова, так и словосочетания [Riedl, Biemann, 2018, с. 519]. После токенизации может выполняться фильтрация стоп-слов [Sarica, Luo, 2021, с. 1], то есть слов не обладающих значимой семантической нагрузкой (например, предлоги и союзы). Для сокращения разнообразия словоформ применяются процедуры морфологической нормализации, наибо-

лее распространёнными из которых являются стемминг и лемматизация [Balakrishnan, Lloyd-Yemoh, 2014, с. 263]. Стемминг заключается в приведении слова к его основе посредством удаления суффиксов и окончаний. При лемматизации слово преобразуется в свою словарную форму (лемму) с учётом его морфологических характеристик. Примеры методов обработки представлены в таблице 1.3.

Таблица 1.3: Примеры основных методов предварительной обработки текста

Метод	Описание	Пример
Токенизация	Разбиение текста на элементарные единицы анализа: слова или словосочетания.	«я читаю газеты дома» → [я, читаю, газеты, дома]
Удаление стоп-слов	Исключение общеупотребительных слов, не обладающих значимой семантической нагрузкой.	[я, читаю, газеты, дома] → [читаю, газеты, дома]
Стемминг	Сведение слова к основе путём отсечения окончаний и суффиксов.	«голосование», «голосовал», «голосующий» → «голос»
Лемматизация	Приведение слова к словарной форме с учётом морфологических характеристик.	«читали», «читает», «читаю» → «читать»

Для применения моделей машинного обучения текстовые данные необходимо преобразовать в числовое представление, среди наиболее распространённых методов преобразования текста в числовую форму выделяют Bag of Words и TF-IDF [Akuma, Lubem, Adom, 2022, с. 3632]. Bag of Words (мешок слов) является наиболее простым способом представления текстовых данных. Идея данного подхода заключается в том, что текст рассматривается как набор отдельных слов без учёта их порядка и синтаксической структуры. Формируется словарь всех уникальных слов, встречающихся в корпусе текстов, после чего каждый документ представляется вектором, отражающим наличие или частоту этих слов. В простейшем варианте полученный вектор может содержать бинарный факт присутствия слова в документе. Другим распространённым методом векторизации является TF-IDF (term frequency - inverse document frequency). Данный подход позволяет оценить значимость слова в конкретном документе относительно всего корпуса текстов, то есть позволяет выделить редкие слова и уменьшить влияние общеупотребительных слов [Дементьев, Киреев, 2022, с. 26]. Метод основан на двух показателях, первый — частота слова (TF), отражающая, сколько раз слово встречается в данном документе, второй показатель — обратная частота документа (IDF), которая снижает вес слов, часто встречающихся во многих документах корпуса, а итоговое значение TF-IDF определяется как произведение двух этих величин.

Методы Bag of Words и TF-IDF прежде всего рассматривают слова как независимые признаки и не учитывают их контекст и семантические связи, так как игнорируют порядок слов в тексте, что приводит к потере смыслов, что иногда является ограничением методов

[Abubakar, Umar, Bakale, 2022, с. 27]. Для преодоления этих ограничений в современных исследованиях используются эмбединги слов, которые позволяют учитывать семантические связи в тексте. Одним из подходов является Word2Vec, который основан на обучении простой нейронной сети, которая формирует векторные представления слов на основе их контекста и расположения в тексте, используя две основные архитектуры: CBOW, предсказывающая слово по его окружению, и Skip-gram, которая, наоборот, предсказывает контекст по заданному слову, что позволяет эффективно извлекать семантические отношения между словами [Mikolov et al., 2013, с. 10]. Другим методом является GloVe, который в отличие от Word2Vec, использует глобальную статистику совместной встречаемости слов в корпусе текстов [Pennington, Socher, Manning, 2014, с. 1541]. Подход строится на основе матрицы совместных появлений слов и позволяет получить векторные представления, отражающие структуру взаимосвязей между словами, благодаря чему GloVe также способен эффективно выявлять семантические отношения между словами [Rakshit, Sarkar, 2025, с. 983].

Таким образом, методы представления текста в числовой форме различаются по тому, какие свойства текста они способны сохранять: счётные подходы фиксируют главным образом частотные характеристики слов, тогда как эмбединговые модели позволяют учитывать семантические связи между ними. Сравнительные характеристики основных методов представления текста в числовой форме приведены в таблице 1.4, а иллюстративные примеры их применения - в таблице 1.5.

Таблица 1.4: Сравнение основных методов представления текста в числовой форме

Метод	Принцип представления текста	Что учитывает	Основное ограничение
BoW	Вектор частот слов.	Наличие и/или частоту отдельных слов в документе.	Не учитывает порядок слов, контекст и семантические связи между словами.
TF-IDF	Вектор весов слов, где вес определяется частотой слова в документе и редкостью слова в корпусе.	Частоту слова в документе и его информативность относительно корпуса.	Как и Bag of Words, не учитывает порядок слов и контекстуальные связи.
Word2Vec	Векторы, обучаемые на основе локального контекста их употребления в тексте.	Контекст появления слова и его семантическую близость к другим словам.	Обычно присваивает слову один и тот же вектор вне зависимости от конкретного контекста.
GloVe	Векторы, обучаемые на основе глобальной матрицы совместной встречаемости слов в корпусе.	Глобальные статистические связи между словами в корпусе.	Как и Word2Vec, не учитывает контекстуальную изменчивость значения слова в высказывании.

Таблица 1.5: Примеры представления текста различными методами векторизации

Метод	Пример представления	Интерпретация
BoW	<i>Исходный текст:</i> «кот ест рыбу». <i>Словарь корпуса:</i> [кот, ест, рыбу]. <i>Вектор:</i> [1, 1, 1].	Текст представляется как набор частот отдельных слов. Порядок слов и связи между ними не учитываются.
TF-IDF	<i>Исходный текст:</i> «кот ест рыбу». <i>Словарь корпуса:</i> [кот, ест, рыбу]. <i>Вектор весов:</i> слово «рыбу» может получить больший вес, чем слово «ест».	Метод выделяет более информативные для документа слова и уменьшает влияние общеупотребительных слов корпуса.
Word2Vec	<i>Исходные слова:</i> «кошка», «собака», «дом». <i>Результат:</i> слова преобразуются в векторы.	Слова, употребляющиеся в похожих контекстах, получают близкие представления. Поэтому «кошка» и «собака» будут ближе друг к другу, чем к слову «дом».
GloVe	<i>Исходные слова:</i> «король», «королева», «мужчина», «женщина». <i>Результат:</i> слова преобразуются в векторы.	Учёт глобальных семантических связей между словами. Если слова часто встречаются в сходных окружениях, их представления оказываются близкими.

Для решения задачи автоматического кодирования открытых ответов применяются различные методы машинного обучения, которые можно разделить на классические модели машинного обучения и современные модели глубинного обучения.

Сначала рассмотрим классическое машинное обучение.

1.9. Модели классического машинного обучения

«Задача классификации ставится, когда нам необходимо присвоить примеру метку класса или несколько меток классов (в этом случае, задача называется multi-labeling) на основании отличительных особенностей, именуемых признаками. При этом классы представляют собой конечное множество» [Кугаевских, Муромцев, Кирсанова, 2022, с. 4]. К наиболее распространенным и простым алгоритмам для решения этой задачи относятся наивный байесовский классификатор, логистическая регрессия и метод опорных векторов (SVM) [Дьяков, 2014, с. 110-111]. Эти модели широко применяются в задачах классификации благодаря относительной простоте реализации, интерпретируемости и устойчивой работе на небольших обучающих выборках. При этом важно подчеркнуть, что машинное обучение не является универсальным решением всех проблем, так как оно представляет собой набор инструментов, эффективность которых зависит от того, насколько корректно они применяются к конкретной исследовательской задаче, поэтому при использовании любых методов машинного обучения необходимо учитывать особенности данных, цели исследования и критерии

оценки полученных результатов [Grimmer, Roberts, Stewart, 2021, с. 414]. Ниже дадим краткую характеристику моделей.

1.9.1. Логистическая регрессия

Модель логистической регрессии строится на основе линейной комбинации признаков, после чего полученное значение преобразуется в вероятность с помощью логистической функции. Это определено тем, что нам известно, что включить в регрессионную модель дихотомическую переменную в качестве зависимой нельзя, однако это можно сделать, если использовать функцию логит [Крыштановский, 2006, с. 182].

Пусть каждому наблюдению соответствует вектор признаков $x = (x_1, x_2, \dots, x_p)$, а зависимая переменная y принимает два значения: $y \in 0, 1$. В отличие от линейной регрессии, где предсказывается числовое значение зависимой переменной, в логистической регрессии рассчитывается вероятность принадлежности объекта к положительному классу:

$$P(y = 1 | x) = \frac{1}{1 + e^{-z}} \quad (1.1)$$

$$z = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p \quad (1.2)$$

Иначе говоря, модель сначала строит линейную комбинацию признаков, а затем преобразует её в значение от 0 до 1 с помощью логистической функции. Полученная величина интерпретируется как вероятность того, что объект принадлежит классу 1.

Эквивалентная запись модели задаётся через логит-преобразование вероятности:

$$\log \left(\frac{P(y = 1 | x)}{1 - P(y = 1 | x)} \right) = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p \quad (1.3)$$

Такая форма показывает, что логистическая регрессия рассчитывает не саму вероятность, а логарифм отношения шансов принадлежности к положительному классу как линейную функцию признаков.

После оценки параметров модели вероятность сравнивается с некоторым порогом c , чаще всего $c = 0.5$. Тогда правило классификации имеет вид:

$$\hat{y} = \begin{cases} 1, & \text{если } P(y = 1 | x) \geq c \\ 0, & \text{если } P(y = 1 | x) < c \end{cases} \quad (1.4)$$

Оценивание коэффициентов логистической регрессии, как правило, осуществляется методом максимального правдоподобия. В задачах машинного обучения это эквивалентно минимизации логистической функции потерь:

$$L(\beta) = - \sum_{i=1}^n [y_i \log p_i + (1 - y_i) \log(1 - p_i)], \quad (1.5)$$

где $p_i = P(y_i = 1 \mid x_i)$ — предсказанная моделью вероятность для i -го наблюдения.

Логистическая регрессия позволяет не только отнести объект к одному из классов, но и получить интерпретируемую оценку вероятности его принадлежности к заданному классу. Сочетание интерпретируемости, простоты реализации и устойчивой работы на небольших выборках делает данную модель одной из наиболее распространённых для классификации в задачах машинного обучения.

Можем на примере этой базовой модели рассмотреть, какие независимые переменные будут поданы на вход и какая переменная будет зависимой. При этом нужно отметить, что выбор конкретной модели для примера в данном случае не является принципиальным с точки зрения постановки задачи. Независимо от используемого алгоритма (логистическая регрессия, SVM, ансамблевые методы и др.), задача сводится к предсказанию решения кодировщика на основе текстовых признаков. Различия между моделями заключаются не в определении зависимой и независимых переменных, а в способе аппроксимации зависимости между ними с помощью различных функций.

Рассмотрим пример кодирования ответов на вопрос: «Почему Вы поддерживаете данную политическую партию?». Предположим, что исследователя интересует категория «экономическая мотивация». Тогда зависимая переменная y_i задаётся следующим образом:

$$y_i = \begin{cases} 1, & \text{если ответ } i \text{ отнесён кодировщиком к категории «экономическая мотивация»} \\ 0, & \text{если ответ не отнесён к данной категории} \end{cases}$$

Таким образом, y_i является кодом, обозначающим содержательную характеристику ответа на вопрос, которая зафиксирована в кодбуксе для классификации ответов.

В качестве независимых переменных x_i выступает представление текста ответа в виде набора измеримых признаков, отражающих его лексическое содержание. На практике это может быть вектор частот ключевых слов или TF-IDF-веса слов. Так, для ответа: «Цены растут, налоги увеличиваются, уровень жизни падает» значимыми признаками будут, например: наличие слов «цены», «налоги», «уровень жизни». Формально каждому ответу сопоставляется вектор признаков $x_i = (x_{i1}, x_{i2}, x_{i3}, \dots, x_{ip})$, где каждый x_{ij} отражает присутствие соответствующего смыслового индикатора в тексте (например, TF-IDF для слова). В результате логистическая регрессия оценивает вероятность того, что данный текстовый ответ будет отнесён к категории «экономическая мотивация» на основе совокупности этих признаков.

1.9.2. Наивный байесовский классификатор

Наивный байесовский классификатор основан на теореме Байеса и используется для оценки вероятности принадлежности объекта к тому или иному классу [Zhang, Li, 2007, с. 708]. Пусть документ представлен вектором признаков $x = (x_1, x_2, \dots, x_p)$, а $y \in \{c_1, c_2, \dots, c_K\}$ обозначает возможные классы. Тогда апостериорная вероятность принадлежности объекта к классу c_k определяется по формуле

$$P(y = c_k | x) = \frac{P(x | y = c_k) P(y = c_k)}{P(x)} \quad (1.6)$$

Поскольку знаменатель $P(x)$ одинаков для всех классов, при классификации достаточно сравнивать только числители. Тогда правило принятия решения можно записать следующим образом:

$$\hat{y} = \arg \max_{c_k \in \{c_1, \dots, c_K\}} P(y = c_k) P(x | y = c_k) \quad (1.7)$$

Основное допущение наивного байесовского классификатора заключается в условной независимости признаков внутри каждого класса [Ting, Ip, Tsang, 2011, с. 37]. Это означает, что при фиксированном классе значения признаков считаются независимыми друг от друга:

$$P(x | y = c_k) = \prod_{j=1}^p P(x_j | y = c_k) \quad (1.8)$$

Тогда правило классификации принимает вид

$$\hat{y} = \arg \max_{c_k \in \{c_1, \dots, c_K\}} P(y = c_k) \prod_{j=1}^p P(x_j | y = c_k) \quad (1.9)$$

В задачах классификации текста в качестве признаков обычно рассматриваются слова, токены или их частоты в документе. Тогда модель оценивает вероятность того, что данный набор слов был сгенерирован документом, принадлежащим определённому классу. Иначе говоря, для каждого класса вычисляется произведение вероятностей появления наблюдаемых слов в документах этого класса с учётом априорной вероятности самого класса.

Классификатор называется наивным, поскольку в его основе лежит предположение об условной независимости признаков [Александрова, 2021, с. 335], то есть считается, что слова, присутствующие в одном текстовом документе, не оказывают влияния друг на друга [Xu, 2018, с. 49]. В реальных текстах это предположение обычно не выполняется в строгом виде, так как слова связаны друг с другом синтаксически и семантически.

1.9.3. Метод опорных векторов

Метод опорных векторов (Support Vector Machine, SVM) основан на идее построения разделяющей гиперплоскости, максимально отделяющей объекты различных классов [Cervantes et al., 2020, с. 190]. Пусть каждому объекту соответствует вектор признаков $x_i \in \mathbb{R}^p$, а метка класса принимает значения $y_i \in \{-1, +1\}$. Тогда разделяющая гиперплоскость задается уравнением

$$w^\top x + b = 0, \quad (1.10)$$

где w — вектор весов, определяющий ориентацию гиперплоскости, а b — свободный член.

Решающее правило классификации имеет вид

$$\hat{y} = \text{sign}(w^\top x + b) \quad (1.11)$$

То есть знак линейной функции $w^\top x + b$ определяет, по какую сторону от гиперплоскости располагается объект и, следовательно, к какому классу он относится.

Ключевая идея метода заключается не просто в нахождении любой разделяющей гиперплоскости, а в выборе такой гиперплоскости, которая максимизирует расстояние между наблюдениями разных классов. Считается расстояние от гиперплоскости до ближайших к ней объектов обучающей выборки, называемых опорными векторами. Если данные линейно разделимы, задача оптимизации записывается следующим образом:

$$\min_{w,b} \frac{1}{2} \|w\|^2 \quad (1.12)$$

при ограничениях

$$y_i(w^\top x_i + b) \geq 1, \quad i = 1, \dots, n \quad (1.13)$$

Минимизация нормы $\|w\|^2$ эквивалентна максимизации ширины разделяющего расстояния, поэтому SVM стремится построить классификатор, обладающий высокой обобщающей способностью на новых данных.

На практике классы часто не являются строго линейно разделимыми. В этом случае используется SVM с расстоянием, допускающим наличие ошибок классификации. Тогда задача принимает вид

$$\min_{w,b,\xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i \quad (1.14)$$

при ограничениях

$$y_i(w^\top x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0, \quad i = 1, \dots, n, \quad (1.15)$$

где ξ_i — штрафы за нарушения разделимости, а параметр $C > 0$ регулирует компромисс между шириной зазора и числом ошибок на обучающей выборке.

Мы рассмотрели базовые модели: логистическую регрессию, наивный байесовский классификатор, SVM.

Помимо прочего одним из важных направлений в развитии методов классификации являются ансамблевые методы машинного обучения, которые объединяют несколько базовых моделей для получения более точного и устойчивого результата [Кугаевских, Муромцев, Кирсанова, 2022, с. 5]. В отличие от использования одной модели, ансамбли позволяют уменьшить влияние случайных ошибок и повысить качество предсказаний.

1.9.4. Случайный лес

Случайный лес представляет собой ансамбль деревьев решений, строящихся с использованием двух источников случайности [Breiman, 2001, с. 5]. Во-первых, каждое дерево обучается на bootstrap-выборке, то есть на случайной выборке с возвращением того же объёма, что и исходная обучающая выборка. Во-вторых, при каждом разбиении узла рассматривается не всё множество признаков, а лишь случайно выбранное подмножество [Bentéjac, Csörgő, Martínez-Muñoz, 2021, с. 1939]. Такая процедура позволяет повысить устойчивость ансамбля.

Пусть исходная обучающая выборка имеет вид

$$D = \{(x_i, y_i)\}_{i=1}^n, \quad (1.16)$$

где $x_i \in \mathbb{R}^p$ — вектор признаков, а y_i — метка класса. Для каждого дерева $b = 1, \dots, B$ случайным образом формируется bootstrap-выборка

$$D^{(b)} \sim D, \quad (1.17)$$

на которой обучается дерево решений $T_b(x)$.

В каждом узле дерева из полного множества признаков размера p случайно выбирается подмножество

$$M \subset \{1, 2, \dots, p\}, \quad |M| = m, \quad m < p \quad (1.18)$$

и поиск наилучшего разбиения производится только среди признаков из множества M . Если обозначить критерий качества разбиения через $\Delta(j, s)$, где j — признак, а s — порог разбиения, то на каждом узле выбирается пара

$$(j^*, s^*) = \arg \max_{j \in M, s} \Delta(j, s) \quad (1.19)$$

В задаче классификации итоговое предсказание случайного леса определяется правилом большинства голосов:

$$\hat{y}(x) = \text{mode}(T_1(x), T_2(x), \dots, T_B(x)) \quad (1.20)$$

Если требуется оценка вероятности принадлежности к классу k , то она может быть вычислена как доля деревьев, проголосовавших за этот класс:

$$\hat{P}(y = k | x) = \frac{1}{B} \sum_{b=1}^B \mathbf{1}(T_b(x) = k) \quad (1.21)$$

Смысл ансамблевого построения состоит в том, что каждое отдельное дерево решений является высоковариативной моделью: небольшое изменение обучающей выборки может привести к иной структуре дерева и, следовательно, к изменению предсказаний. Случайный лес уменьшает эту нестабильность за счёт усреднения большого числа слабокоррелированных деревьев. В терминах ошибки ансамбля это означает снижение дисперсии итогового предсказания при сохранении относительно малого смещения. Именно поэтому одним из главных преимуществ случайного леса является способность давать качественные предсказания даже без сложной настройки гиперпараметров [Bernard, Heutte, Adam, 2009, с. 178]. Кроме того, метод считается сравнительно устойчивым к переобучению [Breiman, 2001, с. 29].

Для оценки качества случайного леса также важна идея наблюдений out-of-bag [Cutler, Cutler, Stevens, 2012, с. 9]. Поскольку каждое дерево обучается на bootstrap-выборке, часть исходных наблюдений не попадает в выборку $D^{(b)}$ для данного дерева. Эти наблюдения могут использоваться как внутренний механизм валидации. Если обозначить через $\mathcal{B}_i$ множество деревьев, при построении которых наблюдение i не использовалось, то out-of-bag-предсказание для этого наблюдения определяется как

$$\hat{y}_i^{\text{OOB}} = \text{mode}\{T_b(x_i) : b \in \mathcal{B}_i\} \quad (1.22)$$

На основе таких предсказаний можно получить оценку ошибки ансамбля без выделения отдельной тестовой выборки.

1.9.5. Градиентный бустинг

Идея градиентного бустинга заключается в объединении большого числа слабых моделей в более точную итоговую модель [Freund, Schapire, Abe, 1999, с. 2]. В процессе обучения модели добавляются поочередно, при этом каждая новая модель ориентируется на ошибки, допущенные предыдущими моделями [Bentéjac, Csörgő, Martínez-Muñoz, 2021, с. 1940]. Чаще всего в качестве базовых моделей в градиентном бустинге используются деревья решений небольшой глубины, что позволяет контролировать сложность модели, тем не менее,

последовательное добавление моделей может приводить к переобучению.

Пусть обучающая выборка имеет вид

$$D = \{(x_i, y_i)\}_{i=1}^n, \quad (1.23)$$

где x_i — вектор признаков, а y_i — целевая переменная. В градиентном бустинге итоговая модель строится как сумма слабых моделей:

$$F_M(x) = \sum_{m=0}^M \gamma_m h_m(x), \quad (1.24)$$

где $h_m(x)$ — очередная базовая модель, γ_m — её вес, а M — число итераций.

Построение ансамбля начинается с некоторого начального приближения

$$F_0(x) = \arg \min_{\gamma} \sum_{i=1}^n L(y_i, \gamma), \quad (1.25)$$

где $L(y, F(x))$ — функция потерь, зависящая от истинного значения и предсказания модели.

На каждой итерации m строится новая модель, которая аппроксимирует отрицательный градиент функции потерь по текущему предсказанию:

$$r_{im} = - \left[\frac{\partial L(y_i, F(x_i))}{\partial F(x_i)} \right]_{F(x)=F_{m-1}(x)}, \quad i = 1, \dots, n \quad (1.26)$$

Величины r_{im} называют псевдоостатками. Именно на них обучается очередная слабая модель:

$$h_m(x) \approx r_{im} \quad (1.27)$$

После этого подбирается коэффициент γ_m , минимизирующий функцию потерь:

$$\gamma_m = \arg \min_{\gamma} \sum_{i=1}^n L(y_i, F_{m-1}(x_i) + \gamma h_m(x_i)) \quad (1.28)$$

Тогда обновление ансамбля записывается как

$$F_m(x) = F_{m-1}(x) + \gamma_m h_m(x) \quad (1.29)$$

Таким образом, каждая новая модель не строится независимо от предыдущих, как в случайном лесе, а последовательно исправляет уже сделанные ошибки [Sevgin, 2023, с. 547].

В задачах классификации итоговое предсказание может быть получено через знак или максимум соответствующей функции оценки:

$$\hat{y}(x) = \text{sign}(F_M(x)) \quad (1.30)$$

для бинарной классификации, либо

$$\hat{y}(x) = \arg \max_k F_{M,k}(x) \quad (1.31)$$

в многоклассовом случае.

На практике в алгоритмах градиентного бустинга обычно используется дополнительный параметр скорости обучения $\eta \in (0, 1]$, который делает обновление более осторожным [Bentéjac, Csörgő, Martínez-Muñoz, 2021, с. 1941]:

$$F_m(x) = F_{m-1}(x) + \eta \gamma_m h_m(x) \quad (1.32)$$

Использование малого значения η позволяет повысить устойчивость модели [Friedman, 2001, с. 1203], однако требует большего числа итераций [Natekin, Knoll, 2013, с. 20]. В целом, градиентный бустинг является одним из наиболее эффективных ансамблевых методов [Grinsztajn, Oyallon, Varoquaux, 2022, с. 5; McElfresh et al., 2023, с. 10; Shwartz-Ziv, Armon, 2022, с. 89] и широко применяется в задачах классификации [Florek, Zagdanski, 2023, с. 29].

Теперь рассмотрим современные модели глубинного обучения.

1.10. Модели глубинного обучения

С развитием методов глубинного обучения задача классификации текста получила значительный импульс [Luan, Lin, 2019, с. 352]. В отличие от традиционных алгоритмов машинного обучения, которые используют заранее подготовленные признаки, нейронные сети способны автоматически извлекать информативные представления текста в процессе обучения [LeCun et al., 2002, с. 2317]. Одними из первых нейронных архитектур, применяемых для анализа текстов, стали сверточные нейронные сети (Convolutional Neural Networks, CNN). Сверточные нейронные сети являются разновидностью многослойных нейронных сетей, обучение которых основано на алгоритме обратного распространения ошибки и направлено на автоматическое извлечение признаков из входных данных. Другим важным классом являются рекуррентные нейронные сети (Recurrent Neural Networks, RNN), которые в отличие от сверточных сетей, учитывают последовательную структуру текста [Luan, Lin, 2019, с. 352]. Под RNN в работе понимается общее семейство рекуррентных сетей. Их особенностью является наличие рекуррентных связей, позволяющих передавать информацию между последовательными шагами обработки [Созыкин, 2017, с. 35]. Однако базовые рекуррентные сети сталкиваются с проблемами обучения на длинных последовательностях. Для решения этой проблемы были предложены сети долго-краткосрочной памяти (Long Short-Term Memory, LSTM), которые используют специальные механизмы управления потоками информации. Более компактной альтернативой LSTM является GRU (Gated Recurrent Unit) [Irie et al., 2016, с. 3520], которая и будет использоваться в работе.

Применение рекуррентных нейросетей связано с ограничениями, вытекающими из

того, что модели обрабатывают последовательность токенов последовательно, что затрудняет моделирование дальних зависимостей между словами и существенно увеличивает вычислительные затраты при работе с длинными текстами. Поэтому отдельно стоит упомянуть, что для решения этих проблем была предложена архитектура трансформеров, которые в отличие от рекуррентных моделей не обрабатывают текст последовательно, а используют механизм, позволяющий учитывать взаимосвязи между всеми элементами текста одновременно, благодаря которому модель может анализировать контекст слова с учётом всего текста [Vaswani et al., 2017, с. 9]. Архитектура трансформеров включает несколько слоёв, основанных на механизме, который позволяет модели определять важность различных слов в предложении относительно друг друга, что позволяет учитывать контекстуальные зависимости между словами независимо от их расстояния в тексте. В зависимости от структуры выделяют несколько основных типов трансформеров, в частности, encoder-only и decoder-only модели [Kora, Mohammed, 2023, с. 61]. Encoder-only применяются преимущественно для задач анализа текста, к ним, например, относится модель BERT, а decoder-only модели используются для генерации текста, к такой категории относятся модели семейства GPT. Таким образом, современным этапом развития методов обработки естественного языка стали большие языковые модели (LLM), основанные на архитектуре трансформеров [Zhang et al., 2025, с. 1524]. Они обучены на масштабных корпусах текстов и способны решать широкий спектр задач анализа и генерации текста, благодаря чему могут использоваться для классификации текстов без необходимости обучения модели с нуля или с минимальной дополнительной настройкой. Одним из преимуществ LLM является способность учитывать контекст текста и выполнять задачи классификации на основе текстовых инструкций исследователя [Мошкин и др., 2025, с. 619]. Другим преимуществом LLM является то, что после дополнительной настройки уже предобученных моделей можно значительно улучшить качество предсказаний на основе данных конкретной области [Wei et al., 2023, с. 2787]. При этом, несмотря на текущую распространённость больших генеративных моделей по типу ChatGPT, для задач классификации текста модели меньшего размера, прошедшие тонкую настройку на размеченных данных, могут демонстрировать более высокую точность по сравнению с генеративными моделями, применяемыми без дополнительного обучения [Bucher, Martini, 2024, с. 13].

Ниже кратко рассмотрим каждую из упомянутых архитектур.

1.10.1. Сверточные нейронные сети

Сверточные нейронные сети (*Convolutional Neural Networks, CNN*) первоначально получили широкое распространение в задачах компьютерного зрения, однако впоследствии стали применяться и для анализа текстов [Luan, Lin, 2019, с. 4]. В задачах классификации текста CNN используются для автоматического извлечения локальных признаков, соответствующих устойчивым сочетаниям слов или токенов. В отличие от моделей классического машинного обучения, которые работают с заранее построенными признаками, сверточная сеть самостоятельно обучает набор фильтров, выявляющих информативные шаблоны

во входной последовательности.

Пусть входной текст представлен последовательностью из n токенов, каждому из которых соответствует векторное представление размерности d . Тогда весь текст можно записать в виде матрицы

$$X \in \mathbb{R}^{n \times d}, \quad (1.33)$$

где каждая строка $x_i \in \mathbb{R}^d$ соответствует эмбедингу i -го слова.

Сверточный фильтр ширины h охватывает подряд идущие h токенов и задаётся матрицей весов

$$W \in \mathbb{R}^{h \times d} \quad (1.34)$$

Для каждого окна $X_{i:i+h-1}$, состоящего из подряд идущих токенов с позиции i до позиции $i + h - 1$, вычисляется сверточный признак

$$c_i = f(\langle W, X_{i:i+h-1} \rangle + b), \quad (1.35)$$

где $\langle W, X_{i:i+h-1} \rangle$ обозначает скалярное произведение фильтра и соответствующего фрагмента текста, b — свободный коэффициент, а $f(\cdot)$ — нелинейная функция активации, например ReLU [Agarap, 2018, с. 5].

В результате применения фильтра ко всем допустимым окнам текста формируется карта признаков

$$c = [c_1, c_2, \dots, c_{n-h+1}] \quad (1.36)$$

Поскольку один и тот же фильтр применяется к различным формам текста [Wang et al., 2020, с. 250], сеть способна выявлять одинаковые локальные шаблоны независимо от их положения в последовательности. Для агрегирования информации по всему множеству признаков обычно используется операция pooling [Zhou, 2022, с. 4]. Наиболее распространённым вариантом является max-pooling:

$$\hat{c} = \max\{c_1, c_2, \dots, c_{n-h+1}\} \quad (1.37)$$

Такая операция сохраняет наиболее сильный отклик фильтра, то есть наиболее значимый локальный паттерн, найденный в тексте [Er et al., 2016, с. 390]. Если используется несколько фильтров различной ширины, например $h = 2, 3, 4$, то после применения свёртки и pooling формируется набор признаков

$$z = [\hat{c}_1, \hat{c}_2, \dots, \hat{c}_m], \quad (1.38)$$

где m — число используемых фильтров.

Полученный вектор признаков передаётся в полносвязный слой, который формирует итоговое предсказание класса. Для многоклассовой классификации обычно используется

функция softmax:

$$P(y = k | x) = \frac{\exp(a_k)}{\sum_{j=1}^K \exp(a_j)}, \quad (1.39)$$

где a_k — значение логита для класса k , а K — число классов.

Таким образом, в задачах классификации текста сверточная нейронная сеть извлекает локальные текстовые паттерны, агрегирует наиболее значимые из них и на их основе выполняет отнесение текста к одному из классов [Jacovi, Shalom, Goldberg, 2018, с. 56]. Преимуществом CNN является способность эффективно обнаруживать информативные признаки, например, последовательности слов, устойчивые фразы или характерные выражения [Goldberg, 2016, с. 385], однако ограничением является то, что в отличие от рекуррентных и трансформерных архитектур сверточные сети в меньшей степени ориентированы на моделирование дальних зависимостей между словами [Wu, Liu, Wang, 2020, с. 1315].

1.10.2. Рекуррентные нейронные сети

Рекуррентные нейронные сети (*Recurrent Neural Networks, RNN*) предназначены для обработки последовательных данных, в которых порядок элементов имеет принципиальное значение [Schmidt, 2019, с. 1]. В отличие от сверточных сетей, ориентированных прежде всего на выделение локальных шаблонов, RNN последовательно обрабатывают входные токены и на каждом шаге обновляют внутреннее скрытое состояние, содержащее информацию о ранее просмотренной части последовательности.

Пусть входной текст представлен последовательностью векторов

$$x_1, x_2, \dots, x_T, \quad (1.40)$$

где $x_t \in \mathbb{R}^d$ — векторное представление t -го токена, а T — длина последовательности. Тогда на каждом шаге t рекуррентная сеть вычисляет скрытое состояние h_t по правилу

$$h_t = \phi(W_x x_t + W_h h_{t-1} + b), \quad (1.41)$$

где W_x — матрица весов для входного вектора, W_h — матрица рекуррентных весов, b — вектор смещений, а $\phi(\cdot)$ — нелинейная функция активации, например, ReLU.

Таким образом, скрытое состояние h_t зависит одновременно от текущего входа x_t и от предыдущего скрытого состояния h_{t-1} [Chen, 2016, с. 2]. Это означает, что сеть на каждом шаге накапливает информацию о предшествующих элементах последовательности. Если развернуть рекуррентное соотношение по времени, становится видно, что состояние h_t в некотором смысле содержит информацию обо всех предыдущих токенах $x_1, \dots, x_t$.

В задачах классификации текста итоговое представление последовательности может

быть построено на основе последнего скрытого состояния:

$$h_T = \phi(W_x x_T + W_h h_{T-1} + b) \quad (1.42)$$

Затем на его основе вычисляются логиты классов:

$$a = W_o h_T + b_o, \quad (1.43)$$

где W_o и b_o — параметры выходного слоя. Для многоклассовой классификации вероятности классов обычно определяются с помощью функции softmax:

$$P(y = k | x) = \frac{\exp(a_k)}{\sum_{j=1}^K \exp(a_j)}, \quad (1.44)$$

где K — число классов.

В более общем виде для классификации можно использовать не только последнее состояние h_T , но и агрегированное представление всей последовательности, например среднее или максимум по всем скрытым состояниям:

$$\bar{h} = \frac{1}{T} \sum_{t=1}^T h_t \quad (1.45)$$

Тогда именно $\bar{h}$ подаётся на выходной классификатор.

Обучение рекуррентной сети осуществляется методом обратного распространения ошибки во времени (*Backpropagation Through Time, BPTT*) [Schmidt, 2019, с. 2]. При этом ошибка, вычисленная на выходе модели, распространяется назад по всей цепочке состояний $h_1, h_2, \dots, h_T$. Именно такая схема обучения позволяет сети адаптировать параметры с учётом последовательной структуры данных [Salehinejad et al., 2017, с. 18].

Основное достоинство RNN в задачах классификации текста состоит в том, что сеть учитывает порядок слов и может моделировать зависимость текущего представления от ранее встреченных токенов, соответственно это делает рекуррентные сети более подходящими для анализа последовательностей [Zulqarnain et al., 2020, с. 326], чем методы, полностью игнорирующие порядок слов. Однако базовые RNN сталкиваются с серьёзной проблемой при работе с длинными последовательностями, поскольку в процессе распространения градиента по многим временным шагам его величина может либо стремиться к нулю, либо, напротив, неограниченно возрастать [Pascanu, Mikolov, Bengio, 2013, с. 2], в результате чего сеть испытывает трудности при обучении долгосрочных зависимостей между удалёнными токенами текста.

1.10.3. Трансформеры

Применение рекуррентных нейросетей связано с ограничениями, вытекающими из последовательной обработки токенов: это затрудняет моделирование дальних зависимостей между словами и увеличивает вычислительные затраты при работе с длинными текстами. Для преодоления этих ограничений была предложена архитектура трансформеров, в которой обработка последовательности строится не на рекуррентном обновлении скрытого состояния, а на механизме внимания (*attention*), позволяющем каждому элементу входа учитывать все остальные элементы последовательности [Vaswani et al., 2017, с. 9].

Пусть входная последовательность состоит из T токенов, каждому из которых соответствует векторное представление размерности d . Вход можно записать в виде матрицы

$$X \in \mathbb{R}^{T \times d} \quad (1.46)$$

Для каждого токена строятся три новых представления: запрос (*query*), ключ (*key*) и значение (*value*). Они вычисляются как линейные преобразования входной матрицы:

$$Q = XW^Q, \quad K = XW^K, \quad V = XW^V, \quad (1.47)$$

где

$$W^Q \in \mathbb{R}^{d \times d_k}, \quad W^K \in \mathbb{R}^{d \times d_k}, \quad W^V \in \mathbb{R}^{d \times d_v} \quad (1.48)$$

являются обучаемыми матрицами параметров.

Механизм внимания определяет, насколько сильно каждый токен должен учитывать остальные токены последовательности. Для этого сначала вычисляется матрица попарных скалярных произведений запросов и ключей:

$$QK^\top \quad (1.49)$$

Затем эти значения масштабируются и нормируются с помощью функции softmax:

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^\top}{\sqrt{d_k}} \right) V \quad (1.50)$$

Эта формула является центральной для архитектуры трансформеров. Матрица

$$\text{softmax} \left(\frac{QK^\top}{\sqrt{d_k}} \right) \quad (1.51)$$

содержит веса внимания, показывающие, насколько каждый токен ориентируется на остальные токены входной последовательности. После умножения на матрицу V получается новое контекстуализированное представление токенов, в котором информация о каждом слове уже зависит от всего предложения.

Иначе говоря, если в рекуррентной сети информация передаётся шаг за шагом вдоль последовательности, то в трансформере каждый токен может непосредственно взаимодействовать с любым другим токеном. Благодаря этому модель способна эффективнее учитывать дальние зависимости между словами.

На практике в трансформерах используется не один механизм внимания, а несколько параллельных голов внимания (*multi-head attention*). Для каждой головы вычисляются собственные матрицы запросов, ключей и значений:

$$Q_i = XW_i^Q, \quad K_i = XW_i^K, \quad V_i = XW_i^V, \quad (1.52)$$

после чего результат каждой головы определяется как

$$\text{head}_i = \text{Attention}(Q_i, K_i, V_i) \quad (1.53)$$

Затем результаты всех голов конкатенируются и линейно преобразуются:

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W^O, \quad (1.54)$$

где h — число голов внимания, а W^O — обучаемая матрица выходного преобразования.

Использование нескольких голов внимания позволяет модели одновременно учитывать разные типы связей между токенами, например локальные, синтаксические и более дальние семантические зависимости.

Поскольку сам механизм внимания не содержит информации о порядке токенов, в трансформерах дополнительно используется позиционное кодирование, которое позволяет включить сведения о позиции слова в последовательности. В простейшем виде итоговое входное представление задаётся как сумма эмбединга токена и его позиционного вектора:

$$Z = X + P, \quad (1.55)$$

где P — матрица позиционных кодировок.

Архитектура трансформеров позволяет строить контекстуализированные представления текста, в которых значение каждого токена определяется с учётом всей последовательности и на сегодняшний день это делает трансформеры наиболее эффективными для задач анализа текста, где важно учитывать дальние зависимости между словами и сложные контекстуальные связи между ними.

Мы рассмотрели как модели классического машинного обучения, так и глубинного обучения. Но для того, чтобы сравнивать их качество требуется введение соответствующих метрик для задачи классификации.

1.11. Метрики оценки качества классификации

Для оценки качества моделей классификации и их последующего сравнения между собой используются различные метрики, основанные на сравнении предсказанных и фактических классов [Hossin, Sulaiman, 2015, с. 4]. Эти метрики вычисляются на основе матрицы ошибок, которая содержит количество верно и неверно классифицированных объектов. Элементами матрицы являются истинно положительные (true positive, TP), истинно отрицательные (true negative, TN), ложноположительные (false positive, FP) и ложноотрицательные (false negative, FN) предсказания.

	Предсказан +	Предсказан -
Фактически +	TP	FN
Фактически -	FP	TN

Самой распространённой метрикой качества классификации является Ассигасу, которая показывает долю правильно классифицированных объектов среди всех наблюдений и вычисляется как отношение суммы истинно положительных и истинно отрицательных предсказаний к общему числу объектов.

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (1.56)$$

Precision (точность положительных предсказаний) показывает, какая доля объектов, отнесённых моделью к положительному классу, действительно относится к нему.

$$\text{Precision} = \frac{TP}{TP + FP} \quad (1.57)$$

Recall (полнота) отражает долю правильно найденных объектов положительного класса среди всех объектов положительного класса.

$$\text{Recall} = \frac{TP}{TP + FN} \quad (1.58)$$

Для одновременной оценки точности и полноты часто используется F_1 -мера, представляющая собой гармоническое среднее значений метрик precision и recall.

$$F_1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \quad (1.59)$$

В случае задачи многоклассовой классификации рассмотренные метрики считаются для каждого класса отдельно, то есть каждый класс по очереди рассматривается как положительный, а остальные как отрицательные, после чего результаты усредняются [Muhammad, Rehman, Shoaib, 2017, с. 374]. Наиболее распространёнными являются макро-усреднение,

при котором метрики вычисляются отдельно для каждого класса и затем усредняются, и *micro*-усреднение, при котором сначала суммируются значения истинно положительных, ложноположительных и ложноотрицательных предсказаний по всем классам, а затем вычисляется итоговая метрика.

Пусть всего имеется K классов, а значение метрики для класса k обозначено как M_k . Тогда *macro*-усреднение определяется как простое среднее по всем классам:

$$M_{\text{macro}} = \frac{1}{K} \sum_{k=1}^K M_k \quad (1.60)$$

В случае *micro*-усреднения сначала суммируются значения истинно положительных, ложноположительных и ложноотрицательных предсказаний по всем классам:

$$TP_{\text{micro}} = \sum_{k=1}^K TP_k, \quad FP_{\text{micro}} = \sum_{k=1}^K FP_k, \quad FN_{\text{micro}} = \sum_{k=1}^K FN_k \quad (1.61)$$

Тогда, например, *micro-precision* и *micro-recall* вычисляются как

$$\text{Precision}_{\text{micro}} = \frac{TP_{\text{micro}}}{TP_{\text{micro}} + FP_{\text{micro}}} \quad (1.62)$$

$$\text{Recall}_{\text{micro}} = \frac{TP_{\text{micro}}}{TP_{\text{micro}} + FN_{\text{micro}}} \quad (1.63)$$

Micro-F₁ определяется через них стандартным образом.

Теперь для наглядности расчёта базовых метрик качества классификации рассмотрим условный пример результатов работы модели. Предположим, что модель на тестовой выборке дала следующие результаты:

	Предсказан +	Предсказан -
Фактически +	40	10
Фактически -	5	45

Следовательно, $TP = 40$, $FN = 10$, $FP = 5$, $TN = 45$, тогда

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} = \frac{40 + 45}{40 + 45 + 5 + 10} = \frac{85}{100} = 0.85 \quad (1.64)$$

$$\text{Precision} = \frac{TP}{TP + FP} = \frac{40}{40 + 5} = \frac{40}{45} \approx 0.889 \quad (1.65)$$

$$\text{Recall} = \frac{TP}{TP + FN} = \frac{40}{40 + 10} = \frac{40}{50} = 0.8 \quad (1.66)$$

$$F_1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} = 2 \cdot \frac{0.889 \cdot 0.8}{0.889 + 0.8} \approx 0.842 \quad (1.67)$$

Проинтерпретируя значения метрик в данном примере, получаем, что модель правильно классифицирует 85% объектов, при этом среди всех объектов, отнесённых к положительному классу, около 88.9% действительно являются положительными, а среди всех фактически положительных объектов модель находит 80%.

1.12. Эмпирические исследования сравнения моделей

Одной из ранних и наиболее значимых работ в области автоматического кодирования открытых ответов является исследование 2003 года, в котором задача кодирования осмыслена как задача многоклассовой классификации текста [Giorgetti, Sebastiani, 2003, с. 1276]. Анализировались ответы на открытые вопросы из General Social Survey (GSS), проводимого National Opinion Research Center (NORC) в США. По большей части выборка была представлена ответами респондентов на вопрос о ситуации, когда респондент в последний месяц испытывал сильный гнев, раздражение или досаду, и должен был описать, что именно вызвало это чувство. Авторы сравнивали словарные методы и ML-модели, а именно, наивный байесовский классификатор и метод опорных векторов. Результаты показали, что ML-модели значительно превосходили старый словарный подход, благодаря чему ассурасу (доля верных предсказаний) возросла с 0.495 (для лучшего словарного метода) до 0.585 для наивного байесовского классификатора и до 0.626 для SVM, тем самым, работа показала, что автоматизация кодирования открытых ответов может быть эффективно реализована через методы классического машинного обучения с учителем.

Другим современным исследованием 2022 года по кодированию открытых ответов с помощью классических ML-моделей является исследование на основе данных GESIS Panel с ответами респондентов на вопрос: «Почему вы участвуете в опросах панели?» [Haensch et al., 2022, с. 8]. Подход идентичен прошлому исследованию, авторы имели 5 тыс. ответов закодированных вручную ответов, а остальная часть (20 тыс. ответов) классифицированы моделью. Авторы протестировали наивный байесовский классификатор и SVM, а также рассмотрели логистическую регрессию и случайный лес. Наилучшие результаты показала модель SVM, которая достигла ассурасы = 0.93 и макро- $F_1 = 0.83$.

Что касается применения трансформерных архитектур, лучше всего рассмотреть исследование, в котором осуществлялась классификация открытых ответов из проекта ANES (American National Election Studies) [Meidinger, Aßenmacher, 2021, с. 8]. Упомянутое исследование по сравнению моделей является очень наполненным, поэтому я хотел бы остановиться на нём подробнее. Выборка взята из опроса, который является одним из авторитетных

и долгосрочных, проводится в США с 1948 года и изучает электоральные предпочтения респондентов до выборов и после выборов, каждые президентские выборы проводится временная серия опросов [Bartels, 1999, с. 2]. Респондентов спрашивают о причинах голосования, оценке кандидатов, проблемах страны, симпатиях и антипатиях к партиям. Датасет, который использовали авторы для своего исследования очень важен в контексте задачи кодирования в социальных науках, поскольку ранее практически не было открытых стандартизованных датасетов-бэнчмарков для открытых ответов респондентов. Этот датасет уже содержит ответы на разные вопросы и имеет ручную разметку профессиональных кодировщиков. Авторы разбили вопросы из ANES по тематическим блокам и сформировали 10 датасетов, каждый из которых соответствовал определённым смысловым типам вопросов. Размер выборок различался от 238 наблюдений для вопросов о причинах победы кандидата и результатах выборов до 8399 наблюдений для вопросов о наиболее важных проблемах страны. Количество категорий кодирования также варьировалось от 9 до 72 меток, собственно поэтому задача классификации была многомерной, поскольку одному текстовому ответу могло соответствовать несколько кодов.

Авторы сравнили базовую модель на основе логистической регрессии и fastText эмбедингов против трансформерных архитектур BERT, RoBERTa и XLNet, которые были дообучены на данных опроса. Качество модели оценивалось с помощью нескольких метрик, специфичных для многомерной классификации, а именно, sample-based F_1 , micro- F_1 , macro- F_1 , subset accuracy. Метрика sample-based F_1 измеряет среднюю точность предсказания меток для каждого ответа, micro- F_1 отражает общую точность наиболее частых категорий, тогда как macro- F_1 позволяет оценить качество предсказания для редких категорий. Полученные результаты показали, что эффективность моделей существенно зависит от размера датасета, из-за чего на наименьших выборках (238 и 288 ответов) трансформеры буквально не смогли обучиться, из-за чего получили критически низкий sample-based F_1 , который равен 0.00 и 0.02 соответственно, тогда как базовая модель логистической регрессии имело качество 0.44 и 0.51 соответственно. На средних и крупных датасетах (от 2 до 8 тыс. ответов) RoBERTa и XLNet достигали хорошего качества по sample-based F_1 до 0.98 на вопросах по распознаванию политиков и партийных симпатий, при этом базовая модель логистической регрессии на тех же данных демонстрировала сопоставимые результаты, достигая качества 0.95. Стоит отметить интересный факт, который сделали исследователи при сравнении метрики macro- F_1 , отражающей качество классификации редких категорий. По ней логистическая регрессия оставалась наиболее устойчивой, поскольку, например, на одном из крупных датасетов значение macro- F_1 составило 0.46 для логистической регрессии, тогда как для трансформеров оно было существенно ниже: 0.09 для BERT, 0.14 для RoBERTa и 0.16 для XLNet. Исходя из проведённых авторами экспериментов следует, что сложные нейросетевые модели лучше справлялись с частыми категориями, но хуже распознавали редкие коды. В целом, результаты показали, что классические методы машинного обучения, такие как логистическая регрессия, основанная на эмбедингах слов, демонстрируют сопоставимое или даже более высокое качество кодирования, чем современные трансформерные архитектуры,

особенно в условиях ограниченного объёма обучающих данных, при этом являются значительно более простыми в реализации и доступны широкому кругу исследователей.

1.13. Резюме теоретической главы

В социальных науках открытые вопросы позволяют фиксировать смыслы, не навязанные исследователем заранее, но в то же время они требуют трудоёмкой процедуры перевода свободных формулировок респондентов в необходимые аналитические категории. Для решения задачи классификации применяются как классические модели машинного обучения, так и современные модели глубинного обучения, при этом эффективность конкретного подхода зависит от структуры задачи, объёма обучающих данных. В проведённых эмпирических исследованиях мы увидели, что классические методы нередко остаются конкурентоспособными, особенно при ограниченном объёме данных.

Глава 2

Методология сравнительного анализа

2.1. Основные понятия

В таблице 2.1 раскроем интерпретацию и операционализацию основных понятий, использованных при создании программы исследования.

Таблица 2.1: Основные понятия исследования

Термин	Интерпретация	Операционализация
Модель	алгоритм классификации, сопоставляющий текстовому ответу одну из категорий кодировки на основе закономерностей, выявленных в размеченных данных	модели классического машинного обучения и модели глубинного обучения
Качество классификации	степень соответствия категориальных меток, предсказанных моделью, меткам ручной кодировки, принимаемой в исследовании в качестве эталонной	samples F_1 -score
Тип открытого вопроса	характеристика открытого вопроса, отражающая степень интерпретативной неопределённости, семантической вариативности ответов и структуру пространства допустимых категорий	технически открытые, кажущиеся открытыми и действительно открытые вопросы

2.2. Эмпирическая база

Эмпирическую основу данного исследования составляют корпуса открытых ответов, имеющие готовую ручную кодировку, выступающую в качестве обучающей выборки для моделей машинного обучения применительно к задаче классификации. Используется база ответов на открытые вопросы из исследования American National Election Studies (ANES).

Для исторической справки, ANES это долгосрочная серия исследований обществен-

ного мнения и политического поведения в США [Miller, 1994, с. 247]. Задача проекта состоит в предоставлении данных, позволяющих анализировать выбор того или иного кандидата и другие аспекты электорального поведения. Истоки проекта восходят к национальному опросу, проведённому до и после президентских выборов 1948 года силами Мичиганского университета. В дальнейшем исследования были институционализированы и с 1977 года оформлены как American National Election Studies. Одной из характеристик ANES является временная сопоставимость волн исследования, поскольку проект изначально развивался как серия повторяющихся обследований, позволяющих анализировать как отдельные электоральные кампании, так и изменения политических установок во времени [Bartels, 1999, с. 2]. Сбор данных в ANES традиционно осуществлялся посредством личных интервью по месту жительства респондентов [Malhotra, Krosnick, 2007, с. 287]. Респондентами являются взрослые граждане США. Дизайн исследования опирается на стратифицированную выборку. Она строится как многоступенчатая географическая кластерная выборка: сначала отбираются крупные географические единицы, затем более мелкие территориальные сегменты, далее — домохозяйства, а после этого — один респондент внутри домохозяйства [DeBell, 2024, с. 178]. То есть, если в домохозяйстве проживает несколько лиц, удовлетворяющих критериям исследования, отбирается только один из них, это необходимо для сохранения вероятностной логики выборки и снижения систематических искажений, связанных с доступностью респондентов.

Теперь подробнее остановимся на конкретном наборе данных, который будет использоваться в текущей работе — ANES 2008 Open Ended Coding Project. В 2008 году в выборку вошло 2102 жителя США, имеющих право голоса. Для начала опишем процесс, по которому проводилось кодирование открытых ответов: сначала для каждого тематического блока разрабатывалась кодировочная рамка, то есть набор категорий, которые должны были быть содержательно осмысленными, взаимно различимыми и в совокупности покрывать пространство возможных ответов респондентов. Затем для кодировщиков составлялись инструкции, в которых фиксировались правила выделения смысловых единиц в ответе, порядок присвоения кодов и трактовка неоднозначных случаев. После этого проводилось независимое пробное кодирование подвыборок ответов, результаты которого использовались для уточнения инструкций. Полное кодирование всех открытых ответов осуществляли два профессиональных кодировщика, работавших независимо друг от друга. Каждый кодировщик присваивал ответам категории в соответствии с финальной версией инструкций и после завершения независимого кодирования результаты сопоставлялись. Все случаи расхождений возвращались тем же кодировщикам на процедуру согласования, на которой кодировщики объясняли основания своих собственных первоначальных решений, а затем совместно вырабатывали итоговый набор кодов, который оба признавали наиболее точным. Именно эти согласованные коды и становились финальной версией кодов на открытые ответы, которые будут использоваться в текущей работе.

Эмпирическая база хорошо подходит для моего исследования по сравнению моделей

машинного обучения в качестве кодирования, поскольку содержит подходящие открытые вопросы двух типов: *действительно открытые* и *кажущиеся открытыми* (согласно классификации определённой при обзоре литературы). Данная база уже была использована в исследовании по кодированию открытых ответов с помощью машинного обучения [Meidinger, ABenmacher, 2021, с. 867], но авторы не исследовали зависимость качества работы моделей для разных типов вопросов согласно их содержательной классификации, а также использовали ограниченный набор моделей.

Вся база состоит из 10 наборов данных. Размер наборов данных прописан в таблице 2.2. В каждом наборе данных содержатся ответы на один или несколько открытых вопросов. Вопросы объединялись не произвольным образом: каждый набор данных представляет собой блок вопросов, для которых в ANES 2008 Open Ended Coding Project использовалась общая кодировочная рамка. Иначе говоря, внутри одного набора данных объединяются вопросы, кодируемые через единое пространство содержательных категорий. Например, в 1 и 2 наборах данных объединяются вопросы о победе и поражении кандидатов на всеобщих выборах и праймериз, поэтому можно логично объединить внутри набора данных ответы немного разных, но концептуально очень близких вопросов, которые приводятся к одному набору категорий кодирования.

Таблица 2.2: Размеры наборов данных

Датасет	Тема объединения вопросов	Переменная вопроса из ANES 2008	Ответы, шт.	Коды, шт
1	Всеобщие выборы	T5, T6	238	34
2	Праймериз	T2, T3	288	29
3	Отношение к партиям	C1b, C1d, C2b, C2d	4393	33
4	Отношение к кандидатам	A8b, A8d, A9b, A9d	4672	34
5	Терроризм	S1	2100	26
6	Важнейшие проблемы страны	Q3a1, Q3a2, Q3b1, Q3b2	8399	72
7	Знание политика: Гордон Браун	J3c	2096	9
8	Знание политика: Дик Чейни	J3b	2094	11
9	Знание политика: Нэнси Пелоси	J3a	2094	14
10	Знание политика: Джон Робертс	J3d	2092	9

Дальнейшее понимание вопросов в рамках текущей работы опирается не только на их схожую форму, но и на содержательную характеристику вопроса. Именно поэтому все 10 наборов данных целесообразно разделить на две группы, интересующих меня типов вопросов.

В наборах данных с 1 по 6 содержатся *действительно открытые* вопросы, поскольку в этих вопросах респонденту предлагается самостоятельно произвести объяснение, дать

оценку или сделать тематическое выделение проблем страны, а исследователь не располагает заранее всем известным и исчерпывающим множеством допустимых ответов. Сюда относятся вопросы о причинах победы и поражения кандидатов, симпатиях и антипатиях к партиям и кандидатам, интерпретации целей террористов, а также о наиболее важных политических проблемах. Во всех этих случаях ответы респондентов могут существенно варьироваться по содержанию и степени абстрактности, а итоговая кодировочная рамка нужна именно для того, чтобы аналитически упорядочить это заранее нефиксированное смысловое разнообразие. Именно по этой причине вопросы в наборах данных с 1 по 6 нельзя интерпретировать как *кажущиеся открытыми*, поскольку вопросы в этих наборах данных предполагают продуцирование новых смыслов респондентами, которые затем подлежат аналитическому кодированию. Так, в вопросах о причинах электорального исхода респонденты могут ссылаться на личные качества кандидатов, кампанию, идеологию, экономическую ситуацию, действия оппонента и иные основания, заранее не сводимые к ограниченному перечню вариантов. Аналогично, в вопросах о партиях, кандидатах и наиболее важных проблемах содержание ответа не определяется заранее и может включать неожиданные, комбинированные или контекстно специфические аргументы респондента. Следовательно, в этих наборах данных кодирование направлено именно на восстановление сложной содержательной структуры открытого ответа, а не на распознавание заранее заданного ограниченного набора очевидных категорий.

Иной логике подчинены вопросы, содержащиеся в наборах данных с 7 по 10, которые посвящены распознаванию должности публичной фигуры. Формально эти вопросы также записываются как открытые, поскольку респондент дает ответ в свободной словесной форме, однако по содержательной структуре они относятся к *кажущимся открытыми*. В данном случае исследователь заранее знает, какое множество допустимых ответов является правильным: речь идет о названии конкретной политической должности. Иными словами, пространство возможных ответов здесь принципиально уже, чем в *действительно открытых* вопросах: респондент не конструирует новое объяснение политической реальности, а воспроизводит или не воспроизводит известный факт.

В таблице 2.3 ниже систематизируем точные формулировки заданных вопросов из оригинального исследования, а также зафиксируем их содержательную классификацию как *действительно открытых* или *кажущихся открытыми вопросов*. В таблицу 4 приложения вынесены все коды и их содержательные названия, которые использовались при кодировании открытых ответов на все вопросы.

Таблица 2.3: Открытые вопросы ANES 2008

Тип	Формулировка вопроса
Действ. откр.	T5: <i>WHY do you think Barack Obama won the Presidential election?</i> T6: <i>WHY do you think John McCain lost the Presidential election?</i>
Действ. откр.	T2: <i>WHY do you think Barack Obama won the Democratic nomination?</i> T3: <i>WHY do you think Hillary Clinton lost the Democratic nomination?</i>
Действ. откр.	C1b: <i>Is there anything in particular that you LIKE about the DEMOCRATIC PARTY?</i> C1d: <i>Is there anything in particular that you DON'T LIKE about the DEMOCRATIC PARTY?</i> C2b: <i>Is there anything in particular that you LIKE about the REPUBLICAN PARTY?</i> C2d: <i>Is there anything in particular that you DON'T LIKE about the REPUBLICAN PARTY?</i>
Действ. откр.	A8b: <i>Is there anything in particular about BARACK OBAMA that might make you want to vote for HIM?</i> A8d: <i>Is there anything in particular about BARACK OBAMA that might make you want to vote against HIM?</i> A9b: <i>Is there anything in particular about JOHN MCCAIN that might make you want to vote for HIM?</i> A9d: <i>Is there anything in particular about JOHN MCCAIN that might make you want to vote against HIM?</i>
Действ. откр.	S1: <i>As you know, on September 11th 2001, a group of terrorists took control of several U.S. commercial airplanes and crashed them into the World Trade Center in New York and the Pentagon in Washington. What do you think the terrorists were trying to accomplish by their actions?</i>
Действ. откр.	Q3a1: <i>What do you think is the most important political problem facing the United States today?</i> Q3a2: <i>What do you think is the second most important political problem facing the United States today?</i> Q3b1: <i>What has been the most important issue to you personally in this election?</i> Q3b2: <i>What has been the second most important issue to you personally in this election?</i>
Каж. откр.	J3c: <i>Now we have a set of questions concerning various public figures. We want to see how much information about them gets out to the public from television, newspapers and the like. GORDON BROWN. What job or political office does he NOW hold?</i>
Каж. откр.	J3b: <i>Now we have a set of questions concerning various public figures. We want to see how much information about them gets out to the public from television, newspapers and the like. DICK CHENEY. What job or political office does he NOW hold?</i>
Каж. откр.	J3a: <i>Now we have a set of questions concerning various public figures. We want to see how much information about them gets out to the public from television, newspapers and the like. The first name is NANCY PELOSI. What job or political office does she NOW hold?</i>
Каж. откр.	J3d: <i>Now we have a set of questions concerning various public figures. We want to see how much information about them gets out to the public from television, newspapers and the like. JOHN ROBERTS. What job or political office does he NOW hold?</i>

2.3. Экспериментальный дизайн

Задачей экспериментальной части исследования является сравнение качества моделей машинного обучения в задаче автоматического кодирования открытых ответов на двух содержательно различных типах вопросов: действительно открытых и кажущихся открытыми. Задача кодирования определена как задача классификации. При этом в исследовании важно не только установить, какие модели в среднем демонстрируют более высокое качество классификации, но и проверить, являются ли наблюдаемые различия статистически значимыми.

Итак, качество классификации моделей машинного обучения будет сравниваться на разных типах открытых вопросов: 1. кажущийся открытым, 2. действительно открытый, к которым будут применены разные типы моделей:

1. Модели классического машинного обучения:

- 1.1) Логистическая регрессия
- 1.2) Метод опорных векторов
- 1.3) Наивный байесовский классификатор
- 1.4) Случайный лес
- 1.5) Градиентный бустинг

2. Базовые модели глубинного обучения:

- 2.1) RNN
- 2.2) CNN

3. Трансформерные модели глубинного обучения:

- 3.1) DistilBERT
- 3.2) GigaChat (zero-shot)
- 3.3) GigaChat (few-shot)
- 3.4) GigaChat (in-context learning — ICL)

Выбор именно этих моделей обусловлен тем, что они представляют три разных уровня сложности методов автоматической классификации текстов. Первая группа классических моделей позволяет оценить, насколько хорошо задача решается с помощью базового представления текста и стандартных алгоритмов классификации. Вторая группа включает базовые модели глубинного обучения, которые важны как промежуточный класс моделей между

классическими алгоритмами и трансформерными моделями. RNN позволяет учитывать последовательную структуру текста, а CNN извлекает локальные паттерны в последовательности слов, поэтому обе модели содержательно подходят для задачи классификации открытых ответов [Luan, Lin, 2019, с. 352]. Третья группа включает трансформерные модели глубинного обучения, которые в соответствии с обзором литературы рассматриваются как один из наиболее сильных подходов к работе с текстовыми данными. В качестве encoder-based модели выбран DistilBERT, поскольку он представляет собой компактную версию BERT и позволяет сравнительно быстро дообучить трансформерную модель [Sanh et al., 2019, с. 4] для задачи многометочной классификации. В качестве decoder-based модели используется GigaChat, поскольку он позволяет проверить другой способ решения: не через дообучение классификатора, а через генерацию структурированного ответа по промпту. Конкретно GigaChat выбран в силу удобства работы с API этой модели в России. При этом само семейство моделей GigaChat обучено преимущественно на корпусе английских текстов и представлено вполне конкурентоспособными моделями по сравнению с прочими генеративными моделями, если основываться на существующих бенчмарках [Mamedov et al., 2025, с. 98]. Важно отметить то, что для GigaChat сравниваются три основных режима работы с decoder-моделью [Brown et al., 2020, с. 3]: zero-shot, retrieval few-shot и in-context learning. Это позволяет оценить, насколько качество кодирования генеративной модели зависит от объема контекстной информации, передаваемой в промпт. В zero-shot-режиме модель опирается только на кодбук и текст ответа, в retrieval few-shot-режиме дополнительно используются содержательно похожие (близкие) размеченные примеры из обучающей выборки, а в режиме in-context learning (ICL) в промпт добавляется фиксированный набор размеченных примеров из обучающей выборки [Dong et al., 2024, с. 1108].

При описании эмпирической базы было отмечено, что одному текстовому ответу может соответствовать несколько кодов одновременно, а также то, что в базе есть 10 наборов данных. Наборы данных не объединяются в один общий массив, поскольку они различаются по тематике, формулировкам вопросов и пространствам категорий кодирования. Вместо этого каждый набор данных рассматривается как самостоятельная задача классификации, а дальнейшее сравнение проводится на уровне двух групп наборов данных, которые относятся к разным типам открытых вопросов.

Обозначим $D^{(1)} = \{D_1, D_2, D_3, D_4, D_5, D_6\}$ множество наборов данных, соответствующих действительно открытым вопросам (6 наборов), а через $D^{(2)} = \{D_7, D_8, D_9, D_{10}\}$ множество наборов данных, соответствующих кажущимся открытыми вопросам (4 набора).

Общая схема анализа включает следующие этапы:

1. Разделение данных на обучающие и тестовые наборы

Каждый набор данных D_d разделяется на обучающую и тестовую части, в результате чего формируется 10 независимых пар обучающих и тестовых выборок в соотношении 70/30, которое является наиболее оптимальным [Nguyen et al., 2021, с. 6], соответственно, дальнейший анализ выполняется на 10 тестовых выборках, не пересека-

ющихся между собой.

2. Векторизация текстовых данных

Каждый текстовый ответ преобразуется в числовое представление признаков.

3. Обучение моделей

Для каждого набора данных D_d обучается 5 моделей классического машинного обучения, 2 базовых модели глубинного обучения и 4 трансформерных модели глубинного обучения.

4. Получение предсказаний кодировочных меток

Для каждого ответа в тестовой выборке формируются предсказанные множественные метки $\hat{y}_{di}$, вследствие чего получаем 10 независимых наборов предсказаний.

5. Оценка качества моделей

Для каждого набора данных вычисляется главная метрика качества samples F_1 -score, что приводит к получению 10 значений метрики качества для каждой модели.

6. Агрегация по типам вопросов

Полученные значения метрики качества агрегируются по двум группам данных $D^{(1)}$ и $D^{(2)}$, в результате чего формируются две средние оценки качества для каждого типа вопросов.

7. Статистическая проверка

С помощью бутстрапа формируются эмпирические распределения разностей качества моделей и строятся доверительные интервалы для проверки статистической значимости различий.

Далее подробнее опишем элементы анализа.

Логика сравнений моделей и выбор базовых моделей

В исследовании рассматриваются три семейства моделей: классические модели машинного обучения (ML), а также базовые и трансформерные модели глубинного обучения (DL). В этих семействах выбраны baseline-модели: логистическая регрессия в ML семействе, поскольку она очень простая в прикладных задачах социолога, интерпретируемая и при этом сильная для задач текстовой классификации (тексты часто представляются в виде разреженных признаков и линейные модели хорошо с ними справляются) [Joulin et al., 2017, с. 427; Galke et al., 2022, с. 6; Buckmann, Hill, 2024, с. 29; Fan et al., 2008, с. 1874]. RNN в DL семействе базовых моделей, поскольку рекуррентные нейронные сети являются классическим подходом к обработке последовательных текстовых данных [Xu et al., 2024,

с. 18020]. В группе трансформерных моделей взята DistilBERT, которая представляет собой компактную версию encoder-модели BERT, сохраняющую основные преимущества трансформерных языковых моделей при меньших вычислительных затратах [Sanh et al., 2019, с. 3]. При этом в отличие от decoder-модели GigaChat, которая используется в режиме промптинга без дообучения, DistilBERT дообучается на размеченных данных, соответственно, задаёт понятную точку отсчёта для трансформерного семейства в логике обучения с учителем. Вследствие этого, сравнение строится не по схеме полного попарного сопоставления всех моделей друг с другом, а по простой и интерпретируемой схеме: каждая модель сравнивается только с baseline-моделью внутри соответствующего семейства. Содержательно такой подход обусловлен тем, что, во-первых, в качестве базовых выбраны простые и сильные модели, качество которых по умолчанию удовлетворительно. Во-вторых, это позволяет понять даёт ли конкретная модель выигрыш относительно базовой, что лучше задачи попарного сравнения всех моделей между собой, поскольку результаты получаются более интерпретируемыми и понятными. Наконец, в-третьих, снижается число статистических проверок, соответственно, уменьшается проблема множественной проверки гипотез.

Основная метрика качества

В качестве основной метрики качества используется samples F_1 -score [Gibaja, Ventura, 2015, с. 6]. Выбор этой метрики обусловлен тем, что в настоящем исследовании интерес представляет качество кодирования отдельного ответа как смысловой единицы. Открытый ответ в социологическом опросе представляет собой законченное высказывание респондента, в котором (в зависимости от вопроса) могут одновременно присутствовать несколько смыслов, соответствующих разным кодам кодировочной схемы, которую использует исследователь, именно поэтому для оценки качества автоматического кодирования важно учитывать, насколько точно модель восстанавливает весь набор категорий, присвоенный конкретному ответу. В этом смысле samples F_1 -score лучше соответствует логике кодирования, которое интересует социолога, чем метрики, агрегирующие качество только на уровне отдельных меток. Например, модель может хорошо предсказывать часто встречающиеся категории по всей выборке, но при этом систематически терять второстепенные коды внутри конкретных ответов и для последующего социологического анализа такая ошибка существенна, ведь неполный или избыточный набор кодов может совершенно поменять содержательную интерпретацию ответа респондента и может исказить распределение тем, проблем или изучаемых установок. При этом, samples F_1 -score одновременно учитывает два типа ошибок: пропуск релевантных кодов и добавление лишних кодов. Таким образом, если для некоторого ответа модель должна предсказать сразу несколько кодов, то принципиально важно оценивать не только правильность отдельных кодировочных меток по всей выборке, но и то, насколько хорошо модель восстанавливает весь набор кодов, присвоенный одному конкретному ответу.

Пусть для i -го объекта тестовой выборки набора данных D_d : y_{di} — множество истинных меток; $\hat{y}_{di}^{(m)}$ — множество меток, предсказанных моделью m . Тогда F_1 -score для отдель-

ного объекта определяется как

$$F1_{di}^{(m)} = \frac{2|y_{di} \cap \hat{y}_{di}^{(m)}|}{|y_{di}| + |\hat{y}_{di}^{(m)}|} \quad (2.1)$$

После этого значения усредняются по всем объектам тестовой выборки данного набора данных, и, следовательно, samples F_1 -score модели m на наборе данных D_d задается формулой

$$F1_{d,m} = \frac{1}{n_d} \sum_{i=1}^{n_d} \frac{2|y_{di} \cap \hat{y}_{di}^{(m)}|}{|y_{di}| + |\hat{y}_{di}^{(m)}|}, \quad (2.2)$$

где n_d — число объектов в тестовой выборке набора данных D_d .

Данная метрика является целевой, но дополнительно для информации могут рассчитываться $\text{micro-}F_1$ и $\text{macro-}F_1$, однако они рассматриваются как вспомогательные информационные (объясняющие) показатели и не используются как основа для проверки гипотез.

Оценка прироста качества относительно базовой модели

Для каждой ML-модели m на наборе данных D_d определяется разность в метрике качества по сравнению с базовой моделью (логистической регрессией):

$$\Delta_{d,m}^{ML} = F1_{d,m} - F1_{d,b_{ML}}, \quad (2.3)$$

где b_{ML} — baseline-модель среди классических ML-моделей.

Аналогично для базовой DL-модели m на наборе данных D_d определяется разность в метрике качества по сравнению с базовой моделью (RNN):

$$\Delta_{d,m}^{DL} = F1_{d,m} - F1_{d,b_{DL}}, \quad (2.4)$$

где b_{DL} — baseline-модель среди базовых DL-моделей.

Также для трансформерной DL-модели m на наборе данных D_d определяется разность в метрике качества по сравнению с базовой моделью (DistilBERT):

$$\Delta_{d,m}^{DL} = F1_{d,m} - F1_{d,b_{DL}}, \quad (2.5)$$

где b_{DL} — baseline-модель среди трансформерных DL-моделей.

Интерпретация логична: если $\Delta_{d,m} > 0$, то модель улучшает качество кодирования на наборе данных D_d по сравнению с базовой. Если $\Delta_{d,m} < 0$, то базовая модель показывает лучший результат.

Измерение качества по типу вопроса

Меня интересует сравнение моделей именно на двух типах вопросов, поэтому после расчета приростов качества на одном из наборов данных необходимо перейти от уровня отдельного набора данных к уровню группы наборов данных по типу вопросов, поскольку качество на одном конкретном наборе данных для текущего исследования не имеет содержательной интерпретации. Предлагается считать среднее изменение качества модели m как среднее арифметическое по наборам данных, содержащим вопросы конкретного типа.

Для действительно открытых вопросов есть 6 наборов данных:

$$\bar{\Delta}_{1,m} = \frac{1}{6} \sum_{d \in D^{(1)}} \Delta_{d,m} \quad (2.6)$$

Для кажущихся открытыми вопросов есть 4 набора данных:

$$\bar{\Delta}_{2,m} = \frac{1}{4} \sum_{d \in D^{(2)}} \Delta_{d,m} \quad (2.7)$$

Здесь индекс 1 относится к действительно открытым вопросам, а индекс 2 — к кажущимся открытыми. Стоит подчеркнуть, почему усреднение выполняется именно по наборам данных, а не по отдельным объектам, объединенным в одну общую тестовую выборку. Важно усреднять именно по наборам данных, поскольку это означает, что каждый набор данных вносит одинаковый вклад в итоговую оценку, поэтому большие наборы данных не доминируют над малыми только за счет большего числа объектов.

Оценка статистической значимости

Для проверки статистической значимости различий в метрике качества классификации samples F_1 -score будет применяться бутстрап с построением двустороннего процентильного доверительного интервала при конвенциональном в социальных исследованиях уровне значимости $\alpha = 5\%$ [Leahey, 2005, с. 1; Skipper, Guenther, Nass, 1967, с. 16].

Выбор бутстрапа обоснован тем, что статистика samples F_1 -score, используемая для сравнения качества моделей является сложной, а классические статистические тесты и теоретические законы распределения не позволяют сделать выводы о статистической значимости, поэтому статистическую значимость будем определять эмпирическим путём [Boos, 2003, с. 174]. Процентильный способ построения доверительного интервала выбирается, поскольку он, во-первых, вычислительно прост, во-вторых, показывает правильные результаты в множестве ситуаций применения [Rousseelet, Pernet, Wilcox, 2021, с. 9].

Обоснование выбранного уровня значимости 5% состоит в том, что он позволяет так или иначе сохранить баланс между ошибкой I и II рода [Lehmann, 1958, с. 1172; Тюрин, Макаров, 1998, с. 100]. При этом для меня более опасна ошибка I рода, поскольку по результатам работы я хочу дать методические рекомендации о том, какую модель выбирать для

конкретного типа вопроса. Таким образом, если будет сделан ложноположительный вывод, рекомендация окажется методологически неверной. В то же время, критична будет и про-садка мощности при более значительном сокращении уровня значимости с учётом размера имеющихся выборок.

Обоснование выбора двусторонней постановки альтернативной гипотезы и соответ-ственно доверительного интервала состоит в том, что в исследовании проверяется не только возможность превосходства одной модели над другой в заранее заданном направлении, но и сам факт наличия различий в качестве классификации [Jones, 1952, с. 46]. Поскольку эмпири-чески преимущество может проявиться в любую сторону в зависимости от типа открытого вопроса и характеристик данных, статистическая проверка строится относительно двусто-ронней альтернативы.

Пусть T_d — тестовая выборка набора данных D_d , состоящая из n_d объектов. Для каж-дой бутстрап-репликации $b = 1, \dots, B$ из T_d формируется новая выборка $T_d^{*(b)}$ путем по-вторной выборки n_d объектов с возвращением. Таким образом, в бутстрап-выборке некото-рые ответы могут встречаться несколько раз, а некоторые могут не попасть в нее вовсе. На бутстрап-выборке $T_d^{*(b)}$ заново вычисляются samples F_1 -score для рассматриваемой модели m и samples F_1 -score для соответствующей baseline-модели. Полученные бутстрап-оценки обозначим через $F1_{d,m}^{*(b)}$ и $F1_{d,b}^{*(b)}$. После этого для каждого набора данных и каждой бутстрап-репликации вычисляется бутстрап-оценка прироста:

$$\Delta_{d,m}^{*(b)} = F1_{d,m}^{*(b)} - F1_{d,b}^{*(b)} \quad (2.8)$$

Затем вычисляется среднее изменение качества.

Для действительно открытых вопросов:

$$\bar{\Delta}_{1,m}^{*(b)} = \frac{1}{6} \sum_{d \in D^{(1)}} \Delta_{d,m}^{*(b)} \quad (2.9)$$

Для кажущихся открытыми вопросов:

$$\bar{\Delta}_{2,m}^{*(b)} = \frac{1}{4} \sum_{d \in D^{(2)}} \Delta_{d,m}^{*(b)} \quad (2.10)$$

Повторяя эту процедуру B раз, получаем эмпирическое бутстрап-распределение сред-него изменения качества модели над базовой для каждого типа вопросов. В работе исполь-зуется $B = 10000$ бутстрап-репликаций, что обеспечивает устойчивость оценок [Hesterberg, 2011, с. 508].

$$\left\{ \bar{\Delta}_{k,m}^{*(1)}, \bar{\Delta}_{k,m}^{*(2)}, \dots, \bar{\Delta}_{k,m}^{*(B)} \right\}, \quad k \in \{1, 2\} \quad (2.11)$$

где $k = 1$ — действительно открытые вопросы, а $k = 2$ — кажущимся открытыми.

На основе эмпирического распределения для каждой модели и для каждого типа вопроса строится процентильный доверительный интервал. При этом, так как в исследовании сравнивается несколько моделей, то есть проверяется несколько статистических гипотез одновременно, необходимо контролировать $FWER$ (вероятность ошибки первого рода на уровне семейства гипотез) [Armstrong, 2014, с. 502]. В работе выделяются шесть семейств статистических гипотез, число которых представлено ниже в таблице 2.5.

Таблица 2.5: Количество статистических гипотез

Тип вопросов	Семейство моделей	Сравнения с baseline-моделью	Гипотезы, шт.
Действ. открытые	Классические ML-модели	SVM, наивный байесовский классификатор, случайный лес и градиентный бустинг	4
Действ. открытые	Базовые DL-модели	CNN	1
Действ. открытые	Трансформерные DL-модели	GigaChat zero-shot, GigaChat few-shot и GigaChat ICL	3
Каж. открытыми	Классические ML-модели	SVM, наивный байесовский классификатор, случайный лес и градиентный бустинг	4
Каж. открытыми	Базовые DL-модели	CNN	1
Каж. открытыми	Трансформерные DL-модели	GigaChat zero-shot, GigaChat few-shot и GigaChat ICL	3

Для контроля $FWER$ при МПГ используется поправка Бонферрони как консервативный, но самый простой рабочий вариант [VanderWeele, Mathur, 2019, с. 617]:

$$\alpha_j = \frac{\alpha}{n_j} = \frac{0.05}{n_j}, \quad (2.12)$$

где n_j — количество гипотез в j -том семействе.

Таким образом, в случае МПГ можем получить конкретные скорректированные уровни значимости для построения доверительных интервалов:

$$\alpha_j = \begin{cases} \frac{0.05}{4} = 0.0125, & \text{если } n_j = 4 \\ \frac{0.05}{3} \approx 0.0167, & \text{если } n_j = 3 \end{cases} \quad (2.13)$$

Мы зафиксировали, что для каждого семейства гипотез используется свой скорректированный уровень значимости, после чего на основе эмпирического бутстрап-распределения для каждой модели и для каждого типа вопроса строится процентильный доверительный ин-

тервал, который определяется как:

$$CI_{1-\alpha_j} = [q_{\alpha_j/2}(\bar{\Delta}_{k,m}^*), q_{1-\alpha_j/2}(\bar{\Delta}_{k,m}^*)], \quad (2.14)$$

где $q_p(\bar{\Delta}_{k,m}^*)$ — p -квантиль эмпирического бутстрап-распределения, а α_j — уровень значимости, скорректированный с помощью Бонферрони.

Различие между моделями интерпретируется как статистически значимое, если нулевое значение не принадлежит построенному интервалу: $0 \notin CI_{1-\alpha_j}$. Если же $0 \in CI_{1-\alpha_j}$, то статистически значимых различий между моделями по рассматриваемой метрике не выявляется.

Глава 3

Эмпирические результаты

3.1. Обучение моделей

Перед обсуждением результатов сравнения качества моделей, важно отметить, что данная работа не ставит перед собой инженерной задачи по получению идеального качества предсказаний с полным перебором гиперпараметров конкретной модели. Определённо подбор гиперпараметров является очень ресурсозатратной задачей, особенно в контексте времени обучения больших пайплайнов моделей [Feurer, Hutter, 2019, с. 4], поэтому некоторые параметры модели можно (и бывает целесообразно) задать вручную [Probst, Boulesteix, Bischl, 2019, с. 1-2]. В текущей работе сравнивается сразу несколько различных моделей, поэтому к ним скорее применяется базовая настройка для текущей исследовательской задачи по кодированию ответов базы ANES, схожим образом были проведены предыдущие эмпирические исследования автоматического кодирования [Meidinger, Aßenmacher, 2021, с. 869]. Следовательно, полученные результаты не следует интерпретировать как утверждение о максимально достижимом качестве каждой модели, поскольку они показывают качество моделей, которое просто получить при базовой настройке.

Настройка моделей различалась в зависимости от их группы. Для классических моделей машинного обучения обучение происходило в общем пайплайне на основе библиотеки Scikit-learn, основные параметры моделей и TF-IDF-векторизации были заранее заданы в конфигурации. В частности, фиксировались параметры текстовой векторизации, а также ключевые параметры отдельных классификаторов: регуляризация для логистической регрессии и SVM, параметр сглаживания для наивного байесовского классификатора, число деревьев и глубина для случайного леса и градиентного бустинга.

Для базовых моделей глубинного обучения, представленных CNN и RNN, которые были реализованы с использованием библиотеки PyTorch, токенизированные текстовые ответы подавались в обучаемый слой эмбеддингов. Также тестировались предобученные эмбеддинги GloVe и word2vec. RNN-модель (представленная архитектурой GRU) использовала рекуррентную архитектуру для учета последовательной структуры текста, тогда как CNN-модель извлекала локальные текстовые паттерны с помощью одномерных сверток. Обе мо-

дели обучались с помощью оптимизатора AdamW как многометочные классификаторы с использованием функции потерь BCEWithLogitsLoss, подходящей для независимых предсказаний нескольких меток.

Для трансформерной encoder-модели, представленной DistilBERT, реализованной с помощью библиотеки Hugging Face Transformers, использовалась небольшая процедура подбора гиперпараметров. В частности, рассматривались два режима: файнтюнинг всех слоев DistilBERT и обучение только классификационной головы при других замороженных слоях.

Для трансформерной генеративной decoder-модели, представленной GigaChat (доступ осуществлялся с помощью API к модели GigaChat Lite), не было обучения в классическом смысле слова. Сравнивались разные режимы промптинга: zero-shot, retrieval few-shot и in-context learning, следовательно, различия между вариантами использования GigaChat обусловлены различной организацией входного промпта. Параметры API-запроса были фиксированы, в частности важно отметить, что устанавливалась нулевая температура генерации, что должно было снизить случайность ответов модели. В режиме zero-shot модель получала в промпте только формулировку вопроса, кодбук с описанными категориями и тексты ответов. В режиме retrieval few-shot для промпта и текущего предсказания предоставлялся кодбук и подбирались 10 близких размеченных примеров из обучающей части выборки (ответы векторизовались через TF-IDF, после чего считалась косинусная близость векторов). В режиме in-context learning в промпт, помимо кодбука, добавлялся фиксированный набор из 100 размеченных примеров обучающей выборки. Общая структура промпта во всех режимах задавалась единой инструкцией, которая определяла задачу классификации, допустимый формат ответа и ограничение на использование только кодов из кодбука, а в зависимости от режима использования инструкция дополнялась в соответствии с таблицей 3.1. Сами текстовые ответы были на английском языке, кодбук — тоже, поэтому и инструкции к модели были составлены на английском, чтобы не смешивать языки внутри одной задачи.

Таблица 3.1: Использованные промпты для GigaChat

Режим	Промпт
Общая инструкция	Classify survey open-ended answers into all applicable codebook labels. Use only listed numeric codes. Return only JSON. Do not add explanations.
Zero-shot	Classify the following answers using the codebook.
Retrieval few-shot	Use these labeled examples as guidance. They are semantically close to the current batch.
In-context learning	Use these labeled training examples as guidance.

3.2. Оценка полученного качества классификации

Перейдём к обсуждению результатов обучения моделей и рассмотрим полученное качество классификации в таблице 3.2. Напомню, что в качестве основной метрики используется samples F_1 -score, поскольку задача автоматического кодирования открытых ответов имеет многометочную структуру, то есть одному ответу может соответствовать не одна, а сразу несколько кодировочных категорий. Отсюда прямо следует, что в такой постановке важно оценивать не только то, насколько хорошо модель предсказывает отдельные метки по всей выборке, но и то, насколько точно она восстанавливает полный набор кодов для каждого конкретного ответа.

Таблица 3.2: Среднее по датасетам samples F_1 -score

Модель	Кажущийся открытым вопрос	Действительно открытый вопрос
<i>Классические ML-модели</i>		
SVM	0.93	0.65
Логистическая регрессия	0.92	0.64
Случайный лес	0.92	0.59
Градиентный бустинг	0.91	0.54
Наивный байесовский классификатор	0.84	0.59
<i>Базовые DL-модели</i>		
CNN	0.92	0.56
RNN	0.92	0.52
<i>Трансформерные DL-модели</i>		
DistilBERT	0.60	0.59
GigaChat, in-context	0.46	0.35
GigaChat, retrieval few-shot	0.26	0.26
GigaChat, zero-shot, кодбук	0.17	0.16

Качество классификации существенно различается в зависимости от типа вопроса. Для кажущихся открытыми вопросов почти все классические ML-модели и базовые DL-модели показывают высокие значения samples F_1 : от 0.84 у наивного байесовского классификатора до 0.93 у SVM (что является лучшим результатом). Там, где пространство возможных ответов относительно ограничено, модели достаточно хорошо восстанавливают полный набор кодов для отдельного ответа. Содержательно samples F_1 -score = 0.93 означает, что предсказанные моделью наборы кодов в среднем на 93% совпадают с ручной кодировкой

на уровне отдельных ответов респондентов. На мой взгляд, такое значение метрики можно интерпретировать как очень высокое качество автоматического кодирования, при этом исходя из природы метрики F_1 -score можно сделать вывод также о том, что предсказываемый набор кодировочных меток очень близок к ручной разметке, ведь модель редко пропускает нужные коды и редко добавляет лишние (совмещается точность и полнота предсказаний).

Для действительно открытых вопросов качество заметно ниже. Это ожидаемый результат, поскольку такие вопросы предполагают более разнообразные и содержательно неоднородные ответы, а также более сложное пространство кодировочных категорий. Среди классических моделей лучшие результаты показывают SVM и логистическая регрессия: их средний F_1 составляет 0.65 и 0.64 соответственно. Это уже достаточно умеренное качество классификации, такое значение метрик говорит о том, что модель заметно чаще допускает ошибки: пропускает релевантные коды или добавляет лишние, следовательно, такое качество уже нельзя считать высоким для задачи автоматического кодирования открытых ответов, особенно если результаты предполагается использовать для содержательного социологического анализа (что вообще-то является целью любого кодирования). Базовые DL-модели уступают классическим моделям на действительно открытых вопросах: CNN достигает значения 0.56, а RNN — всего 0.52. Содержательно восстановление в среднем лишь 56% или 52% кодов на уровне отдельного ответа говорит о неприемлемо низком качестве автоматического кодирования. При этом мы помним, что на кажущихся открытыми вопросах CNN и RNN показывают качество, сопоставимое с классическими моделями, следовательно, предполагается, что преимущество базовых нейросетевых архитектур не проявляется устойчиво, то есть они хорошо справляются с более простыми и стандартизированными ответами, но не дают выигрыша на более сложных действительно открытых вопросах.

Отдельно выделяются трансформерные DL-модели. DistilBERT показывает относительно стабильное качество на двух типах вопросов: 0.60 для кажущихся открытыми и 0.59 для действительно открытых. Качество является удовлетворительным, однако на кажущихся открытыми вопросах это качество существенно ниже, чем у классических ML-моделей и базовых DL-моделей. Наименьшие результаты демонстрируют варианты использования GigaChat. Лучшим среди них является режим in-context learning, однако его качество составляет 0.46 на кажущихся открытыми вопросах и 0.35 на действительно открытых вопросах. Retrieval few-shot и zero-shot дают ещё более низкие значения F_1 . Это говорит о том, что в данной задаче генеративная LLM по сути не справляется с кодированием текстовых ответов и применять её в текущей реализации нецелесообразно и опасно. При этом важно отметить, что критически низкий результат GigaChat нужно интерпретировать не как свидетельство общей неэффективности генеративных языковых моделей, а как ограничение конкретного способа их применения в данной задаче кодирования, ведь в моём исследовании GigaChat использовался без дообучения, только через организацию промпта (дообучение такой сложной модели является невозможным в рамках текущего исследования и фактически

невыполнимо в силу технических причин доступа к модели). Однако в семействе трансформерных моделей даже дообученный DistilBERT не демонстрирует лучшего качества по сравнению с классическими ML-моделями, поэтому само по себе использование трансформерной архитектуры не гарантирует прироста качества в рассмотренной задаче кодирования.

В целом, можно заметить, что наиболее сильными моделями в рассматриваемой задаче являются классические ML-модели, прежде всего SVM и логистическая регрессия. Они демонстрируют высокое качество на кажущихся открытыми вопросах и лучшие результаты на действительно открытых вопросах. Это согласуется с теоретическими основаниями использования данных методов, ведь классические линейные модели особенно эффективны в задачах классификации текста, поскольку традиционно используемое TF-IDF-представление текста для классических моделей порождает разреженное пространство признаков, а линейные классификаторы хорошо приспособлены к работе с такими данными [Fan et al., 2008, с. 1871]. Базовые DL-модели оказываются конкурентоспособными только на более простых задачах, тогда как трансформерные подходы не дают устойчивого преимущества в условиях данного исследования.

Таким образом, в прикладном отношении методологической перспективы полученные результаты позволяют уточнить, что автоматическое кодирование в текущей постановке задачи классификации может использоваться как замена ручной работе кодировщиков только для кажущихся открытыми вопросов, у которых пространство возможных ответов относительно ограничено, а ответы часто содержат устойчивые лексические признаки категорий. Результаты эксперимента показывают, что для кодирования ответов на такие вопросы использование классических линейных моделей, прежде всего SVM и логистической регрессии, может быть оправдано как способ существенного сокращения ручного труда (с вытекающими экономическими последствиями) без заметной потери качества кодирования. Рекомендуется автоматизировать кодирование ответов на кажущиеся открытыми вопросы. Иная ситуация наблюдается для действительно открытых вопросов, ведь здесь даже теоретически лучшие модели достигают лишь умеренного качества, а значит, автоматическая разметка пока не может рассматриваться как полноценная замена человеку-кодировщику, поскольку для таких вопросов значительная доля ошибок в предсказаниях моделью машинного обучения имеет более серьёзные последствия, так как пропуск содержательно важного кода или добавление лишней категории может изменить интерпретацию ответа респондента и, следовательно, исказить последующий социологический анализ.

Перейдём к проверке статистической значимости различий в соответствии с методологией исследования. В таблице 3.3 представлены результаты проверки статистической значимости различий между моделями и соответствующими baseline-моделями. В ней анализируются разности в среднем $\text{samples } F_1$ относительно baseline-модели. Положительное значение Δ означает, что рассматриваемая модель превосходит baseline-модель, а отрицательное значение значит, что она уступает ей. Различие считается статистически значимым в том случае, если доверительный интервал для Δ не содержит ноль.

Таблица 3.3: Статистическая проверка различий в samples F_1 относительно baseline-моделей

Семейство	Модель	Baseline	Δ	Дов. интервал		Значимо
				ниж.	верх.	
Кажущиеся открытыми вопросы						
Классические ML-модели	GB	LogReg	−0.0085	−0.0168	−0.0003	Да
Классические ML-модели	NB	LogReg	−0.0783	−0.0894	−0.0673	Да
Классические ML-модели	RF	LogReg	−0.0037	−0.0109	0.0035	Нет
Классические ML-модели	SVM	LogReg	0.0078	0.0026	0.0132	Да
Базовые DL-модели	CNN	RNN	−0.0065	−0.0118	−0.0010	Да
Трансформерные DL-модели	GigaChat ICL	DistilBERT	−0.1347	−0.1685	−0.0999	Да
Трансформерные DL-модели	GigaChat few-shot	DistilBERT	−0.3377	−0.3691	−0.3052	Да
Трансформерные DL-модели	GigaChat zero-shot	DistilBERT	−0.4245	−0.4565	−0.3928	Да
Действительно открытые вопросы						
Классические ML-модели	GB	LogReg	−0.0936	−0.1145	−0.0731	Да
Классические ML-модели	NB	LogReg	−0.0518	−0.0729	−0.0307	Да
Классические ML-модели	RF	LogReg	−0.0449	−0.0652	−0.0244	Да
Классические ML-модели	SVM	LogReg	0.0125	−0.0009	0.0264	Нет
Базовые DL-модели	CNN	RNN	0.0391	0.0226	0.0554	Да
Трансформерные DL-модели	GigaChat ICL	DistilBERT	−0.2385	−0.2774	−0.1993	Да
Трансформерные DL-модели	GigaChat few-shot	DistilBERT	−0.3270	−0.3646	−0.2880	Да
Трансформерные DL-модели	GigaChat zero-shot	DistilBERT	−0.4253	−0.4563	−0.3948	Да

Примечание: Δ показывает разницу в среднем samples F_1 между моделью и соответствующей baseline-моделью. Доверительные интервалы построены на основе бутстрапа с поправкой Бонферрони внутри каждого семейства сравнений (см. методологию, таблица 2.5). Различие считается статистически значимым, если доверительный интервал не содержит ноль.

Для кажущихся открытыми вопросов в группе классических ML-моделей единственной моделью, статистически значимо превосходящей логистическую регрессию, является SVM: прирост составляет 0.0078, однако мы можем заметить, что по величине этот прирост достаточно мал. Наивный байесовский классификатор и градиентный бустинг статистически значимо уступают логистической регрессии, причем наиболее заметное снижение качества наблюдается у наивного байесовского классификатора. Случайный лес не имеет статистически значимых отличий от логистической регрессии. В группе базовых DL-моделей на кажущихся открытыми вопросах CNN статистически значимо уступает RNN, при этом величина различия также невелика. Хотя различие формально является статистически значимым, с практической точки зрения качество на этом типе вопросов остается очень близким. Для трансформерных DL-моделей на кажущихся открытыми вопросах все варианты GigaChat статистически значимо уступают DistilBERT.

Для действительно открытых вопросов ситуация в группе классических ML-моделей несколько отличается. SVM не имеет статистически значимых отличий от логистической регрессии. Следовательно, несмотря на немного более высокое среднее значение F_1 у SVM, строго говоря статистически подтвержденного превосходства над логистической регрессией не выявлено. При этом градиентный бустинг, наивный байесовский классификатор и случайный лес статистически значимо уступают логистической регрессии, поэтому логистическая регрессия остается наиболее устойчивой baseline-моделью среди классических моделей машинного обучения для действительно открытых вопросов. В группе базовых DL-моделей на действительно открытых вопросах CNN статистически значимо превосходит RNN: прирост $F_1 = 0.0391$, то есть для более сложных и содержательно разнообразных открытых ответов CNN оказывается более эффективной базовой нейросетевой архитектурой, чем RNN. Наконец, в группе трансформерных DL-моделей на действительно открытых вопросах все варианты GigaChat также статистически значимо уступают DistilBERT. Как и в случае с кажущимися открытыми вопросами, наилучший результат среди вариантов GigaChat показывает режим in-context learning, однако даже он существенно отстает от DistilBERT. Таким образом, статистическая проверка подтверждает, что использование decoder-модели на примере GigaChat в промпт-режиме без дообучения не обеспечивает качества, сопоставимого с дообученной encoder-моделью.

Подведём выводы по статистической проверке. Во-первых, среди классических ML-моделей логистическая регрессия оказывается очень сильной, SVM значимо превосходит ее только на кажущихся открытыми вопросах, причем с небольшим размером эффекта, а на действительно открытых вопросах значимого превосходства SVM не обнаружено. Во-вторых, CNN имеет преимущество над RNN на действительно открытых вопросах, тогда как на кажущихся открытыми вопросах RNN показывает качество выше. В-третьих, DistilBERT значимо превосходит все варианты GigaChat на обоих типах вопросов, так что генеративные модели в текущей реализации эксперимента не дают преимущества по сравнению с моделями, дообученными на размеченных данных.

Заключение

В данной работе было проведено сравнение результативности моделей машинного обучения для автоматического кодирования открытых ответов в социологических опросах. Основной исследовательский акцент стоял на том, как качество кодирования различается в зависимости от типа открытого вопроса: действительно открытого или кажущегося открытым. Результаты показали, что тип вопроса действительно существенно связан с качеством автоматического кодирования. Кажущиеся открытыми вопросы, в которых пространство возможных ответов относительно ограничено, кодируются моделями заметно лучше, а действительно открытые вопросы, напротив, оказываются более сложными для автоматической классификации, поскольку ответы на них содержательно разнообразнее, а пространство кодировочных категорий шире и неоднороднее. Тем самым, результаты подтверждают важность содержательного различения типов открытых вопросов при оценке качества автоматического кодирования. Сделаем выводы по поставленным исследовательским гипотезам.

1. **Гипотеза 1 не подтвердилась.** На действительно открытых вопросах лучшие результаты показали классические ML-модели, прежде всего SVM и логистическая регрессия. Модели глубинного обучения не продемонстрировали более высокого качества классификации.
2. **Гипотеза 2 не подтвердилась.** GigaChat во всех режимах использования статистически значимо уступает DistilBERT. Следовательно, decoder-based LLM без дообучения не превзошла encoder-based LLM в задаче кодирования действительно открытых вопросов.
3. **Гипотеза 3 подтвердилась частично.** Для кажущихся открытыми вопросов классические ML-модели и базовые DL-модели показывают близкое качество, однако это не распространяется на все модели глубинного обучения: трансформерные модели, особенно GigaChat, заметно уступают лучшим классическим и базовым DL-моделям.

Научная новизна работы состоит в том, что она показывает зависимость качества автоматического кодирования не только от выбранной модели, но и от содержательной структуры открытого вопроса с точки зрения социолога. Для социологической методологии кодирования можно сформировать рекомендацию: использовать известную всем социологам, простую в реализации логистическую регрессию для кодирования кажущихся открытыми

вопросов, поскольку полученный уровень качества кодирования для этого типа вопросов данной моделью вполне высок. А вот кодирование действительно открытых вопросов не стоит автоматизировать, по крайней мере с помощью рассмотренных моделей.

Ограничением исследования является то, что модели сравнивались в условиях базовой прикладной настройки, без исчерпывающего подбора гиперпараметров, поэтому полученные результаты следует интерпретировать как оценку качества моделей в реалистичном сценарии применения в исследовательской практике кодирования социологом, а не как оценку их максимально достижимого качества. Перспективным направлением дальнейших исследований является проверка более сложных стратегий дообучения трансформерных и генеративных моделей. Кроме того, можно рассматривать задачу кодирования не только как классификацию, а как кластеризацию с полуавтоматическим подходом, при которой модель выделяет группы близких ответов, а исследователь затем постепенно интерпретирует и валидирует полученные кластеры.

Список литературы

1. *Александрова М. Ю.* Методы машинного обучения в социологическом исследовании: предсказание частичного неответа с использованием наивного байесовского классификатора // Мониторинг общественного мнения: экономические и социальные перемены. — 2021. — № 1. — С. 329—350.
2. *Дементьев В. Е., Киреев С. Х.* Выбор алгоритмов машинного обучения для классификации текстовых документов // Техника средств связи. — 2022. — 2 (158). — С. 22—52.
3. *Дьяконов А. Г.* Методы решения задач классификации с категориальными признаками // Прикладная математика и информатика. Труды факультета Вычислительной математики и кибернетики МГУ имени М. В. Ломоносова. — 2014. — № 46. — С. 103—127.
4. *Захарова А. В., Вишнякова А. Ю., Детков А. А.* Сравнение моделей и методов классификации текста // Вестник Российского университета дружбы народов. Серия: Инженерные исследования. — 2025. — Т. 26, № 3. — С. 298—309.
5. *Климова С. Г.* Область применения и трудности кодификации открытых вопросов // Социология: Методология, методы, математические модели. — 2006. — № 23. — С. 5—25.
6. *Крыштановский А. О.* Анализ социологических данных с помощью пакета SPSS. — Москва : Издательский дом ГУ ВШЭ, 2006. — 281, [3] с.
7. *Кугаевских А. В., Муромцев Д. И., Кирсанова О. В.* Классические методы машинного обучения. — Санкт-Петербург : Университет ИТМО, 2022. — 53 с.
8. *Мошкин В. С., Казбекова З. Г., Калабихина И. Е., Кашин М. И.* Выбор и настройка больших языковых моделей для классификации текстов в социальных сетях // Информационные процессы. — 2025. — Т. 25, № 3.1. — С. 617—625.
9. *Оберемко О. А.* К типологии открытых вопросов // Мониторинг общественного мнения: экономические и социальные перемены. — 2018. — 4 (146). — С. 97—108.
10. *Рогозин Д. М.* Открытые вопросы в массовых обследованиях // Социологический журнал. — 2001. — № 3. — С. 29—70.

11. *Саганенко Г. И.* Системы, форматы и познавательный потенциал открытых вопросов // Журнал социологии и социальной антропологии. — 2001. — Т. 4, № 4. — С. 171—194.
12. *Созыкин А. В.* Обзор методов обучения глубоких нейронных сетей // Вестник Южно-Уральского государственного университета. Серия: Вычислительная математика и информатика. — 2017. — Т. 6, № 3. — С. 28—59.
13. *Стукал Д. К., Беленков В. Е., Филиппов И. Б.* Методы наук о данных в политических исследованиях: анализ протестной активности в социальных сетях // Политическая наука. — 2021. — № 1. — С. 46—75.
14. *Толстова Ю. Н.* Анализ социологических данных. Методология, дескриптивная статистика, изучение связей между номинальными признаками. — Москва : Научный мир, 2000. — 352 с.
15. *Толстова Ю. Н.* Социология и компьютерные технологии // Социологические исследования. — 2015. — № 8. — С. 3—13.
16. *Тюрин Ю. Н., Макаров А. А.* Статистический анализ данных на компьютере. — Москва : ИНФРА-М, 1998. — 528 с.
17. *Ядов В. А.* Стратегия социологического исследования: описание, объяснение, понимание социальной реальности. — Москва : Добросвет, 2000. — 596 с.
18. *Abubakar H. D., Umar M., Bakale M. A.* Sentiment classification: Review of text vectorization methods: Bag of words, Tf-Idf, Word2vec and Doc2vec // SLU Journal of Science and Technology. — 2022. — Vol. 4, no. 1. — P. 27–33.
19. *Agarap A. F.* Deep learning using rectified linear units (relu) // arXiv preprint arXiv: 1803.08375. — 2018. — P. 1–9.
20. *Aggarwal C. C., Zhai C.* A Survey of Text Classification Algorithms // Mining Text Data. — Boston, MA : Springer US, 2012. — P. 163–222.
21. *Akuma S., Lubem T., Adom I. T.* Comparing Bag of Words and TF-IDF with different models for hate speech detection from live tweets // International Journal of Information Technology. — 2022. — Vol. 14, no. 7. — P. 3629–3635.
22. *Andersen N., Zehner F., Goldhammer F.* Semi-automatic coding of open-ended text responses in large-scale assessments // Journal of Computer Assisted Learning. — 2023. — Vol. 39, no. 3. — P. 841–854.
23. *Arief M., Deris M. B. M.* Text preprocessing impact for sentiment classification in product review // 2021 Sixth International Conference on Informatics and Computing (ICIC). — IEEE. 2021. — P. 1–7.
24. *Armstrong D., Gosling A., Weinman J., Marteau T.* The place of inter-rater reliability in qualitative research: An empirical study // Sociology. — 1997. — Vol. 31, no. 3. — P. 597–606.

25. *Armstrong R. A.* When to use the Bonferroni correction // *Ophthalmic and physiological optics*. — 2014. — Vol. 34, no. 5. — P. 502–508.
26. *Balakrishnan V., Lloyd-Yemoh E.* Stemming and lemmatization: A comparison of retrieval performances // *Lecture notes on software engineering*. — 2014. — Vol. 2, no. 3. — P. 262–267.
27. *Bartels L. M.* Panel effects in the American national election studies // *Political Analysis*. — 1999. — Vol. 8, no. 1. — P. 1–20.
28. *Bentéjac C., Csörgő A., Martínez-Muñoz G.* A comparative analysis of gradient boosting algorithms // *Artificial Intelligence Review*. — 2021. — Vol. 54, no. 3. — P. 1937–1967.
29. *Berardi G., Esuli A., Sebastiani F.* Optimising human inspection work in automated verbatim coding // *International Journal of Market Research*. — 2014. — Vol. 56, no. 4. — P. 489–512.
30. *Bernard S., Heutte L., Adam S.* Influence of hyperparameters on random forest accuracy // *International workshop on multiple classifier systems*. — 2009. — P. 171–180.
31. *Boos D. D.* Introduction to the bootstrap world // *Statistical science*. — 2003. — P. 168–174.
32. *Bradburn N. M., Sudman S., Wansink B.* Asking questions: the definitive guide to questionnaire design - for market research, political polls, and social and health questionnaires. — John Wiley & Sons, 2004. — 446 p.
33. *Breiman L.* Random forests // *Machine learning*. — 2001. — Vol. 45, no. 1. — P. 5–32.
34. *Brown T., Mann B., Ryder N., Subbiah M., Kaplan J. D., Dhariwal P., Neelakantan A., Shyam P., Sastry G., Askell A. et al.* Language models are few-shot learners // *Advances in neural information processing systems*. — 2020. — Vol. 33. — P. 1877–1901.
35. *Bucher M. J. J., Martini M.* Fine-tuned 'small' LLMs (still) significantly outperform zero-shot generative AI models in text classification // *arXiv preprint arXiv:2406.08660*. — 2024. — P. 1–17.
36. *Buckmann M., Hill E.* Logistic regression makes small llms strong and explainable” tens-of-shot” classifiers // *arXiv preprint arXiv:2408.03414*. — 2024. — P. 1–48.
37. *Burrows S., Gurevych I., Stein B.* The eras and trends of automatic short answer grading // *International journal of artificial intelligence in education*. — 2015. — Vol. 25, no. 1. — P. 60–117.
38. *Canché M. S. G.* Machine driven classification of open-ended responses (MDCOR): An analytic framework and no-code, free software application to classify longitudinal and cross-sectional text responses in survey and social media research // *Expert systems with applications*. — 2023. — Vol. 215. — P. 1–21.
39. *Cervantes J., Garcia-Lamont F., Rodríguez-Mazahua L., Lopez A.* A comprehensive survey on support vector machine classification: Applications, challenges and trends // *Neurocomputing*. — 2020. — Vol. 408. — P. 189–215.

40. *Chen G.* A gentle tutorial of recurrent neural network with error backpropagation // arXiv preprint arXiv:1610.02583. — 2016. — P. 1–10.
41. *Converse J. M.* Strong arguments and weak evidence: The open/closed questioning controversy of the 1940s // *Public Opinion Quarterly*. — 1984. — Vol. 48, 1B. — P. 267–282.
42. *Couper M. P., Kennedy C., Conrad F. G., Tourangeau R.* Designing input fields for non-narrative open-ended responses in web surveys // *Journal of official statistics*. — 2011. — Vol. 27, no. 1. — P. 1–25.
43. *Cutler A., Cutler D. R., Stevens J. R.* Random Forests // *Ensemble Machine Learning: Methods and Applications* / ed. by C. Zhang, Y. Ma. — New York, NY : Springer New York, 2012. — P. 157–175.
44. *DeBell M.* American national election studies // *Encyclopedia of Quality of Life and Well-Being Research*. — Springer, 2024. — P. 177–179.
45. *DiGiuseppe M. R., Flynn M. E.* Scaling open-ended survey responses using llm-paired comparisons // *Public Opinion Quarterly*. — 2026. — P. 1–27.
46. *Dong Q., Li L., Dai D., Zheng C., Ma J., Li R., Xia H., Xu J., Wu Z., Chang B. et al.* A survey on in-context learning // *Proceedings of the 2024 conference on empirical methods in natural language processing*. — 2024. — P. 1107–1128.
47. *Er M. J., Zhang Y., Wang N., Pratama M.* Attention pooling-based convolutional neural network for sentence modelling // *Information Sciences*. — 2016. — Vol. 373. — P. 388–403.
48. *Esuli A., Sebastiani F.* Machines that learn how to code open-ended survey data // *International Journal of Market Research*. — 2010. — Vol. 52, no. 6. — P. 775–800.
49. *Fan R.-E., Chang K.-W., Hsieh C.-J., Wang X.-R., Lin C.-J.* LIBLINEAR: A library for large linear classification // *the Journal of machine Learning research*. — 2008. — Vol. 9. — P. 1871–1874.
50. *Feurer M., Hutter F.* Hyperparameter optimization // *Automated machine learning: Methods, systems, challenges*. — Springer, 2019. — P. 3–33.
51. *Fields J., Chovanec K., Madiraju P.* A survey of text classification with transformers: How wide? how large? how long? how accurate? how expensive? how safe? // *Ieee Access*. — 2024. — Vol. 12. — P. 6518–6531.
52. *Florek P., Zagdanski A.* Benchmarking state-of-the-art gradient boosting algorithms for classification // arXiv preprint arXiv:2305.17094. — 2023. — P. 1–41.
53. *Freund Y., Schapire R., Abe N.* A short introduction to boosting // *Journal-Japanese Society For Artificial Intelligence*. — 1999. — Vol. 14, no. 771–780. — P. 1–14.
54. *Friedman J. H.* Greedy function approximation: a gradient boosting machine // *Annals of statistics*. — 2001. — P. 1189–1232.

55. *Galke L., Diera A., Lin B. X., Khera B., Meuser T., Singhal T., Karl F., Scherp A.* Are we really making much progress in text classification? a comparative review // arXiv preprint arXiv:2204.03954. — 2022. — P. 1–46.
56. *Gardazi N. M., Daud A., Malik M. K., Bukhari A., Alsaifi T., Alshemaimri B.* BERT applications in natural language processing: a review // Artificial Intelligence Review. — 2025. — Vol. 58, no. 6. — P. 166.
57. *Gasparetto A., Marcuzzo M., Zangari A., Albarelli A.* A survey on text classification algorithms: From text to predictions // Information. — 2022. — Vol. 13, no. 2. — P. 1–39.
58. *Geer J. G.* Do open-ended questions measure “salient” issues? // Public Opinion Quarterly. — 1991. — Vol. 55, no. 3. — P. 360–370.
59. *Gibaja E., Ventura S.* A tutorial on multilabel learning // ACM Computing Surveys (CSUR). — 2015. — Vol. 47, no. 3. — P. 1–38.
60. *Giorgetti D., Sebastiani F.* Automating survey coding by multiclass text categorization techniques // Journal of the American Society for Information Science and Technology. — 2003. — Vol. 54, no. 14. — P. 1269–1277.
61. *Glazier R. A., Boydston A. E., Feezell J. T.* Self-coding: A method to assess semantic validity and bias when coding open-ended responses // Research & Politics. — 2021. — Vol. 8, no. 3. — P. 1–8.
62. *Goldberg Y.* A primer on neural network models for natural language processing // Journal of Artificial Intelligence Research. — 2016. — Vol. 57. — P. 345–420.
63. *Grimmer J., Roberts M. E., Stewart B. M.* Machine learning for social science: An agnostic approach // Annual Review of Political Science. — 2021. — Vol. 24, no. 1. — P. 395–419.
64. *Grimmer J., Stewart B. M.* Text as data: The promise and pitfalls of automatic content analysis methods for political texts // Political analysis. — 2013. — Vol. 21, no. 3. — P. 267–297.
65. *Grinsztajn L., Oyallon E., Varoquaux G.* Why do tree-based models still outperform deep learning on typical tabular data? // Advances in neural information processing systems. — 2022. — Vol. 35. — P. 507–520.
66. *Groves R. M., Fowler Jr F. J., Couper M. P., Lepkowski J. M., Singer E., Tourangeau R.* Survey methodology. — John Wiley & Sons, 2011. — 496 p.
67. *Haaland I., Roth C., Stantcheva S., Wohlfart J.* Measuring what is top of mind : tech. rep. / ECONtribute Discussion Paper. — 2024. — P. 1–50.
68. *Haensch A.-C., Weiß B., Steins P., Chyrva P., Bitz K.* The semi-automatic classification of an open-ended question on panel survey motivation and its application in attrition analysis // Frontiers in Big Data. — 2022. — Vol. 5. — P. 1–11.

69. *Hesterberg T.* Bootstrap // Wiley Interdisciplinary Reviews: Computational Statistics. — 2011. — Vol. 3, no. 6. — P. 497–526.
70. *Horbach A., Pinkal M.* Semi-supervised clustering for short answer scoring // Proceedings of the Eleventh International Conference on Language Resources and Evaluation (LREC 2018). — 2018. — P. 4065–4071.
71. *Hossin M., Sulaiman M. N.* A review on evaluation metrics for data classification evaluations // International journal of data mining & knowledge management process. — 2015. — Vol. 5, no. 2. — P. 1–11.
72. *Irie K., Tüske Z., Alkhouli T., Schlüter R., Ney H.* et al. LSTM, GRU, highway and a bit of attention: An empirical overview for language modeling in speech recognition // Inter-speech. — 2016. — P. 3519–3523.
73. *Izacard G., Lewis P., Lomeli M., Hosseini L., Petroni F., Schick T., Dwivedi-Yu J., Joulin A., Riedel S., Grave E.* Atlas: Few-shot learning with retrieval augmented language models // Journal of Machine Learning Research. — 2023. — Vol. 24, no. 251. — P. 1–43.
74. *Jacovi A., Shalom O. S., Goldberg Y.* Understanding convolutional neural networks for text classification // Proceedings of the 2018 EMNLP workshop blackboxNLP: analyzing and interpreting neural networks for NLP. — 2018. — P. 56–65.
75. *Joachims T.* A statistical learning model of text classification for support vector machines // Proceedings of the 24th annual international ACM SIGIR conference on Research and development in information retrieval. — 2001. — P. 128–136.
76. *Joachims T.* Text categorization with support vector machines: Learning with many relevant features // European conference on machine learning. — Springer. 1998. — P. 137–142.
77. *Jones L. V.* Test of hypotheses: one-sided vs. two-sided alternatives. // Psychological Bulletin. — 1952. — Vol. 49, no. 1. — P. 43–46.
78. *Joulin A., Grave E., Bojanowski P., Mikolov T.* Bag of tricks for efficient text classification // Proceedings of the 15th conference of the European chapter of the association for computational linguistics: volume 2, short papers. — 2017. — P. 427–431.
79. *Kora R., Mohammed A.* A comprehensive review on transformers models for text classification // 2023 International Mobile, Intelligent, and Ubiquitous Computing Conference (MIUCC). — IEEE. 2023. — P. 1–7.
80. *Leahey E.* Alphas and asterisks: The development of statistical significance testing standards in sociology // Social Forces. — 2005. — Vol. 84, no. 1. — P. 1–24.
81. *LeCun Y., Bottou L., Bengio Y., Haffner P.* Gradient-based learning applied to document recognition // Proceedings of the IEEE. — 2002. — Vol. 86, no. 11. — P. 2278–2324.
82. *Lehmann E. L.* Significance level and power // The Annals of Mathematical Statistics. — 1958. — Vol. 29, no. 4. — P. 1167–1176.

83. *Leiva F. M., Ríos F. J. M., Martínez T. L.* Assessment of interjudge reliability in the open-ended questions coding process // *Quality and Quantity*. — 2006. — Vol. 40, no. 4. — P. 519–537.
84. *Luan Y., Lin S.* Research on text classification based on CNN and LSTM // 2019 IEEE international conference on artificial intelligence and computer applications (ICAICA). — IEEE. 2019. — P. 352–355.
85. *Malhotra N., Krosnick J. A.* The effect of survey mode and sampling on inferences about political attitudes and behavior: Comparing the 2000 and 2004 ANES to Internet surveys with nonprobability samples // *Political Analysis*. — 2007. — Vol. 15, no. 3. — P. 286–323.
86. *Mamedov V., Kosarev E., Leleytner G., Shchuckin I., Berezovskiy V., Smirnov D., Kozlov D., Averkiev S., Ivan L., Proshunin A.* et al. Gigachat family: Efficient russian language modeling through mixture of experts architecture // *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 3: System Demonstrations)*. — 2025. — P. 93–106.
87. *McElfresh D., Khandagale S., Valverde J., Prasad C V., Ramakrishnan G., Goldblum M., White C.* When do neural nets outperform boosted trees on tabular data? // *Advances in Neural Information Processing Systems*. — 2023. — Vol. 36. — P. 1–34.
88. *Meidinger M., Aßenmacher M.* A New Benchmark for NLP in Social Sciences: Evaluating the Usefulness of Pre-trained Language Models for Classifying Open-ended Survey Responses // *Proceedings of the 13th International Conference on Agents and Artificial Intelligence*. Vol. 2. — SCITEPRESS. 2021. — P. 866–873.
89. *Mellon J., Bailey J., Scott R., Breckwoldt J., Miori M., Schmedeman P.* Do AIs know what the most important issue is? Using language models to code open-text social survey responses at scale // *Research & Politics*. — 2024. — Vol. 11, no. 1. — P. 1–7.
90. *Mikolov T., Chen K., Corrado G., Dean J.* Efficient estimation of word representations in vector space // *arXiv preprint arXiv:1301.3781*. — 2013. — P. 1–12.
91. *Miller W. E.* An organizational history of the intellectual origins of the American National Election Studies // *European Journal of Political Research*. — 1994. — Vol. 25, no. 3. — P. 247–265.
92. *Minaee S., Kalchbrenner N., Cambria E., Nikzad N., Chenaghlu M., Gao J.* Deep learning-based text classification: a comprehensive review // *ACM computing surveys (CSUR)*. — 2021. — Vol. 54, no. 3. — P. 1–40.
93. *Montgomery A. C., Crittenden K. S.* Improving coding reliability for open-ended questions // *Public Opinion Quarterly*. — 1977. — Vol. 41, no. 2. — P. 235–243.
94. *Muhammad N. A., Rehman A., Shoaib U.* Accuracy based feature ranking metric for multi-label text classification // *International Journal of Advanced Computer Science and Applications*. — 2017. — Vol. 8, no. 10. — P. 369–378.

95. *Nasteski V.* An overview of the supervised machine learning methods // Horizons. b. — 2017. — Vol. 4, no. 51–62. — P. 1–11.
96. *Natekin A., Knoll A.* Gradient boosting machines, a tutorial // Frontiers in neurorobotics. — 2013. — Vol. 7. — P. 1–21.
97. *Neuert C., Meitinger K., Behr D., Schonlau M.* The use of open-ended questions in surveys // Methods, data, analyses: a journal for quantitative methods and survey methodology (mda). — 2021. — Vol. 15, no. 1. — P. 3–6.
98. *Nguyen Q. H., Ly H.-B., Ho L. S., Al-Ansari N., Le H. V., Tran V. Q., Prakash I., Pham B. T.* Influence of data splitting on performance of machine learning models in prediction of shear strength of soil // Mathematical Problems in Engineering. — 2021. — Vol. 2021, no. 1. — P. 1–15.
99. *O'Connor C., Joffe H.* Intercoder reliability in qualitative research: Debates and practical guidelines // International journal of qualitative methods. — 2020. — Vol. 19. — P. 1–13.
100. *Otter D. W., Medina J. R., Kalita J. K.* A survey of the usages of deep learning for natural language processing // IEEE transactions on neural networks and learning systems. — 2020. — Vol. 32, no. 2. — P. 604–624.
101. *Palanivinayagam A., El-Bayeh C. Z., Damaševičius R.* Twenty years of machine-learning-based text classification: A systematic review // Algorithms. — 2023. — Vol. 16, no. 5. — P. 1–28.
102. *Paleardi F., Novello M.* From words to categories: data quality and the methodological value of open-ended questions in classifying economic activities // Quality & Quantity. — 2025. — P. 1–21.
103. *Pandey D., Niwaria K., Chourasia B.* Machine learning algorithms: a review // Mach. Learn. — 2019. — Vol. 6, no. 2. — P. 916–922.
104. *Pascanu R., Mikolov T., Bengio Y.* On the difficulty of training recurrent neural networks // International conference on machine learning. — Pmlr. 2013. — P. 1310–1318.
105. *Pate R.* Open versus closed questions: What constitutes a good question // Educational research and innovations. — 2012. — P. 29–39.
106. *Pennington J., Socher R., Manning C. D.* Glove: Global vectors for word representation // Proceedings of the 2014 conference on empirical methods in natural language processing (EMNLP). — 2014. — P. 1532–1543.
107. *Popping R.* Analyzing open-ended questions by means of text analysis procedures // Bulletin of Sociological Methodology/Bulletin de Méthodologie Sociologique. — 2015. — Vol. 128, no. 1. — P. 23–39.
108. *Probst P., Boulesteix A.-L., Bischl B.* Tunability: Importance of hyperparameters of machine learning algorithms // Journal of Machine Learning Research. — 2019. — Vol. 20, no. 53. — P. 1–32.

109. *Rajman M., Vesely M.* From text to knowledge: Document processing and visualization: A text mining approach // Text mining and its applications: Results of the NEMIS Launch Conference. — Springer. 2004. — P. 7–24.
110. *Rakshit P., Sarkar A.* A supervised deep learning-based sentiment analysis by the implementation of Word2Vec and GloVe Embedding techniques // Multimedia Tools and Applications. — 2025. — Vol. 84, no. 2. — P. 979–1012.
111. *Ramzan A., Ali R. H., Ali N., Khan A.* Enhancing fake news detection using bert: A comparative analysis of logistic regression, rfc, lstm and bert // 2024 International Conference on IT and Industrial Technologies (ICIT). — IEEE. 2024. — P. 1–6.
112. *Reja U., Manfreda K. L., Hlebec V., Vehovar V. et al.* Open-ended vs. close-ended questions in web questionnaires // Developments in applied statistics. — 2003. — Vol. 19, no. 1. — P. 159–177.
113. *Riedl M., Biemann C.* Using semantics for granularities of tokenization // Computational Linguistics. — 2018. — Vol. 44, no. 3. — P. 483–524.
114. *Roberts M. E., Stewart B. M., Tingley D., Lucas C., Leder-Luis J., Gadarian S. K., Albertson B., Rand D. G.* Structural topic models for open-ended survey responses // American journal of political science. — 2014. — Vol. 58, no. 4. — P. 1064–1082.
115. *Rousselet G. A., Pernet C. R., Wilcox R. R.* The percentile bootstrap: a primer with step-by-step instructions in R // Advances in Methods and Practices in Psychological Science. — 2021. — Vol. 4, no. 1. — P. 1–10.
116. *Rubin O., Herzig J., Berant J.* Learning to retrieve prompts for in-context learning // Proceedings of the 2022 conference of the North American chapter of the association for computational linguistics: human language technologies. — 2022. — P. 2655–2671.
117. *Rudin C.* Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead // Nature machine intelligence. — 2019. — Vol. 1, no. 5. — P. 206–215.
118. *Ryan G. W., Bernard H. R.* Techniques to identify themes // Field methods. — 2003. — Vol. 15, no. 1. — P. 85–109.
119. *Salehinejad H., Sankar S., Barfett J., Colak E., Valaee S.* Recent advances in recurrent neural networks // arXiv preprint arXiv:1801.01078. — 2017. — P. 1–21.
120. *Sanh V., Debut L., Chaumond J., Wolf T.* DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter // arXiv preprint arXiv:1910.01108. — 2019. — P. 1–5.
121. *Sarica S., Luo J.* Stopwords in technical language processing // Plos one. — 2021. — Vol. 16, no. 8. — P. 1–13.
122. *Schierholz M., Schonlau M.* Machine learning for occupation coding—A comparison study // Journal of Survey Statistics and Methodology. — 2021. — Vol. 9, no. 5. — P. 1013–1034.

123. *Schmidt R. M.* Recurrent neural networks (rnns): A gentle introduction and overview // arXiv preprint arXiv:1912.05911. — 2019. — P. 1–16.
124. *Scholz E., Dorer B., Zuell C.* Coding issues of open-ended questions in a cross-cultural context // International journal of sociology. — 2022. — Vol. 52, no. 1. — P. 78–96.
125. *Schonlau M., Couper M. P.* Semi-automated categorization of open-ended questions // Survey Research Methods. Vol. 10. — 2016. — P. 143–152.
126. *Schonlau M., Gweon H., Wenemark M.* Automatic classification of open-ended questions: check-all-that-apply questions // Social Science Computer Review. — 2021. — Vol. 39, no. 4. — P. 562–572.
127. *Schuman H.* The random probe: A technique for evaluating the validity of closed questions // American sociological review. — 1966. — P. 218–222.
128. *Schuman H., Presser S.* The open and closed question // American sociological review. — 1979. — P. 692–712.
129. *Sebastiani F.* Machine learning in automated text categorization // ACM computing surveys (CSUR). — 2002. — Vol. 34, no. 1. — P. 1–47.
130. *Senderovich N., Maysuradze A.* Interactive coding of responses to open-ended questions in Russian // International Conference on Knowledge Engineering and the Semantic Web. — Springer. 2015. — P. 195–209.
131. *Şevgin H.* A comparative study of ensemble methods in the field of education: Bagging and Boosting algorithms // International Journal of Assessment Tools in Education. — 2023. — Vol. 10, no. 3. — P. 544–562.
132. *Shwartz-Ziv R., Armon A.* Tabular data: Deep learning is not all you need // Information fusion. — 2022. — Vol. 81. — P. 84–90.
133. *Skipper J. K., Guenther A. L., Nass G.* The sacredness of. 05: A note concerning the uses of statistical levels of significance in social science // The American Sociologist. — 1967. — P. 16–18.
134. *Stacey M.* Methods of social research: Pergamon international library of science, technology, engineering and social studies. — Elsevier, 2013. — 173 p.
135. *Ting S., Ip W., Tsang A. H.* Is Naive Bayes a good classifier for document classification // International Journal of Software Engineering and Its Applications. — 2011. — Vol. 5, no. 3. — P. 37–46.
136. *Tourangeau R., Rips L. J., Rasinski K.* The psychology of survey response. — Cambridge University Press, 2000. — 401 p.
137. *VanderWeele T. J., Mathur M. B.* Some desirable properties of the Bonferroni correction: is the Bonferroni correction really so bad? // American journal of epidemiology. — 2019. — Vol. 188, no. 3. — P. 617–618.

138. *Vaswani A., Shazeer N., Parmar N., Uszkoreit J., Jones L., Gomez A. N., Kaiser Ł., Polosukhin I.* Attention is all you need // *Advances in neural information processing systems*. — 2017. — Vol. 30. — P. 1–11.
139. *Wang H., He J., Zhang X., Liu S.* A short text classification method based on N-gram and CNN // *Chinese Journal of Electronics*. — 2020. — Vol. 29, no. 2. — P. 248–254.
140. *Wei F., Keeling R., Huber-Fliflet N., Zhang J., Dabrowski A., Yang J., Mao Q., Qin H.* Empirical study of LLM fine-tuning for text classification in legal document review // *2023 IEEE international conference on big data (BigData)*. — IEEE. 2023. — P. 2786–2792.
141. *Woike B. A.* Content coding of open-ended responses // *Handbook of research methods in personality psychology*. — 2007. — P. 292–307.
142. *Wu H., Liu Y., Wang J.* Review of Text Classification Methods on Deep Learning. // *Computers, Materials & Continua*. — 2020. — Vol. 63, no. 3. — P. 1309–1321.
143. *Xu S.* Bayesian Naïve Bayes classifiers to text classification // *Journal of Information Science*. — 2018. — Vol. 44, no. 1. — P. 48–59.
144. *Xu W., Clark S., Brown D., Matos G., Meichanetzidis K.* Quantum recurrent architectures for text classification // *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*. — 2024. — P. 18020–18027.
145. *Young T., Hazarika D., Poria S., Cambria E.* Recent trends in deep learning based natural language processing // *IEEE Computational intelligence magazine*. — 2018. — Vol. 13, no. 3. — P. 55–75.
146. *Zhang H., Li D.* Naïve Bayes text classifier // *2007 IEEE international conference on granular computing (GRC 2007)*. — IEEE. 2007. — P. 708–708.
147. *Zhang R., Gong J., Ma S., Firdaus A., Xu J.* Automatic coding mechanisms for open-ended questions in journalism surveys: An application guide // *Digital Journalism*. — 2023. — Vol. 11, no. 2. — P. 321–342.
148. *Zhang Y., Wang M., Li Q., Tiwari P., Qin J.* Pushing the limit of LLM capacity for text classification // *Companion Proceedings of the ACM on Web Conference 2025*. — 2025. — P. 1524–1528.
149. *Zhou H.* Research of text classification based on TF-IDF and CNN-LSTM // *journal of physics: conference series*. Vol. 2171. — IOP Publishing. 2022. — P. 1–8.
150. *Züll C.* Open-ended questions // *GESIS survey guidelines*. — 2016. — Vol. 3. — P. 1–8.
151. *Zulqarnain M., Ghazali R., Hassim Y. M. M., Rehan M.* A comparative review on deep learning models for text classification // *Indones. J. Electr. Eng. Comput. Sci.* — 2020. — Vol. 19, no. 1. — P. 325–335.

Приложения

1. Кодировочная система ANES 2008

Таблица 4: Используемые коды в ANES 2008 Open Ended Coding Project

Датасет	Переменная	Код	Содержательное название кода
1	T5, T6	1	General
		2	Party
		5	Ideology/Philosophy
		7	Political experience
		8	Military experience
		9	Non-political/Non-military experience
		10	Scandal/Cover-up
		12	Other past activity
		13	Personality - Ability
		14	Personality - Honesty
		15	Personality - Intelligence
		16	Personality - Leadership
		19	Health
		20	Religion
		22	Physical Appearance
		23	Demographics
		26	Policy-Liberty
		27	Policy-Enemy countries
		28	Policy-Friendly countries
		29	Policy-General foreign policy
		30	Policy-Other
		32	Emotions/Feelings
		33	Candidate-Other
		34	Campaign-General
		35	Campaign-Debates

Датасет	Переменная	Код	Содержательное название кода
		36	Campaign-Advertising
		37	Campaign-Speeches
		38	Campaign-Money
		95	Refuse
		96	Respondent-Other
		97	All other
2	T2, T3	1	General
		2	Party
		5	Ideology/Philosophy
		9	Non-political/Non-military experience
		10	Scandal/Cover-up
		12	Other past activity
		13	Personality - Ability
		14	Personality - Honesty
		16	Personality - Leadership
		19	Health
		20	Religion
		21	Education
		23	Demographics
		26	Policy-Liberty
		27	Policy-Enemy countries
		28	Policy-Friendly countries
		29	Policy-General foreign policy
		30	Policy-Other
		33	Candidate-Other
		34	Campaign-General
		35	Campaign-Debates
		37	Campaign-Speeches
		38	Campaign-Money
		95	Refuse
		96	Respondent-Other
		97	All other
3	C1b, C1d, C2b, C2d	1	General
		3	Other party
		4	Specific Person
		5	Ideology/Philosophy
		6	Electability

Датасет	Переменная	Код	Содержательное название кода
		10	Scandal/Cover-up
		11	Campaign
		12	Other past activity
		13	Ability
		14	Honesty
		15	Intelligence
		16	Leadership
		18	Management
		20	Religion
		21	Education
		22	Physical Appearance
		23	Demographics
		24	Policy-Economic
		25	Policy-Poor people
		26	Policy-Liberty
		27	Policy-Enemy countries
		28	Policy-Friendly countries
		29	Policy-General foreign policy
		94	Don't know
		95	Refuse
		96	Respondent-Other
		97	All other
4	A8b, A8d, A9b, A9d	1	General
		2	Party
		5	Ideology/Philosophy
		6	Electability
		7	Political experience
		8	Military experience
		9	Non-political/military experience
		10	Scandal/Cover-up
		12	Other past activity
		13	Personality - Ability
		14	Personality - Honesty
		15	Personality - Intelligence
		16	Personality - Leadership
		17	Personality - Other
		19	Health
		20	Religion

Датасет	Переменная	Код	Содержательное название кода
		21	Education
		22	Physical Appearance
		23	Demographics
		24	Policy-Economic
		25	Policy-Poor people
		26	Policy-Liberty
		27	Policy-Enemy countries
		28	Policy-Friendly countries
		29	Policy-General foreign policy
		30	Policy-Other
		94	Don't know
		95	Refuse
		96	Respondent-Other
		97	All other
5	S1	1	Cause fear
		2	Cause pain
		3	Cause chaos
		4	Kill people
		5	Prove that the United States is weak
		6	Start a war with the United States
		7	Destroy the United States
		8	Destroy democracy
		9	Destroy Western civilization
		10	Destroy the United States' economy
		11	Destroy the United States government
		12	The United States in the Middle East
		13	Get even with the United States -- Other reason
		14	Destroy the twin towers
		15	Destroy a symbol of the United States
		16	Kill George Bush
		17	They are crazy
		18	They are jealous
		19	They hate
		20	They want to be noticed
		21	The US government made them do it
		22	The Muslim religion made them do it
		24	Other comments about the terrorists or attacks
		25	Other comment

Датасет	Переменная	Код	Содержательное название кода
		96	Don't know
		97	Refused
6	Q3a1, Q3a2, Q3b1, Q3b2	1	Defense spending
		2	Middle East
		3	Iraq
		4	War
		5	Terrorism
		6	Veterans
		7	National defense (all other)
		8	Foreign aid
		9	Foreign trade
		10	Protection of US jobs
		12	China
		13	International affairs (all other)
		14	Energy crisis
		15	Energy prices
		16	Energy (all other)
		17	Environment
		18	Natural resources (all other)
		19	Education and training
		20	School funding
		21	Education (all other)
		23	Medicare
		24	Health (all other)
		25	Welfare
		26	Poverty
		27	Employment
		28	Housing
		29	Social security
		30	Income (all other)
		31	Crime
		32	Race relations
		33	Illegal drugs
		34	Police problems
		35	Guns
		36	Corporate corruption
		37	Justice (all other)

Датасет	Переменная	Код	Содержательное название кода
		38	Budget
		39	Size of government
		40	Taxes
		41	Immigration
		43	Political corruption
		44	Ethics
		45	Government power
		46	Budget priorities
		47	Partisan politics
		48	Politicians
		49	Government (all other)
		50	The economy
		51	Stock market
		52	Economic inequality
		53	Recession
		54	Inflation
		55	Economics (all other)
		56	Agriculture
		57	Science
		58	Commerce
		59	Transportation
		60	Community development
		61	Abortion
		62	Child care
		63	Overpopulation
		64	Public morality
		65	Domestic violence
		66	Family
		67	Young people
		68	Homosexuality
		69	The media
		70	Everything
		71	Other
		91	No additional substantive codes
		95	Don't know
		96	Refuse
		97	Respondent (Other)
7	J3c	1	Prime Minister of the United Kingdom

Датасет	Переменная	Код	Содержательное название кода
		3	Prime Minister (Other)
		4	Prime Minister
		11	Head of The United Kingdom
		23	Activity (Other)
		24	Brown (Other)
		95	Don't know
		96	Refuse
		97	Respondent (Other)
8	J3b	1	Vice President of the United States
		3	Vice President (Other)
		4	Vice President
		11	President of the Senate
		21	Leadership activity
		22	First in line
		23	Activity (Other)
		24	Cheney (Other)
		95	Don't know
		96	Refuse
		97	Respondent (Other)
9	J3a	1	Speaker of the House
		2	Speaker of the Congress
		3	Speaker (Other)
		4	Speaker
		11	Head of the House of Representatives
		12	Head of the Congress
		15	Head of the Democrats
		16	Congressperson
		21	Leadership activity
		23	Activity (Other)
		24	Pelosi (Other)
		95	Don't know
		96	Refuse
		97	Respondent (Other)
10	J3d	1	Chief Justice of the Supreme Court
		4	Chief Justice
		11	Head of the Supreme Court
		14	Supreme Court

Датасет	Переменная	Код	Содержательное название кода
		23	Activity (Other)
		24	Roberts (Other)
		95	Don't know
		96	Refuse
		97	Respondent (Other)

2. Репозиторий исследования

Репозиторий с данными, а также кодом на Python для обучения моделей и подведения статистических выводов доступен по ссылке: <https://github.com/kamalov-artur/bachelor-thesis-open-ended-survey-coding>.